

Rapport sur un algorithme de separation de sources acoustiques

A completer

24 août 2026

Résumé

Ce rapport decrit un pipeline de traitement audio multicanal destine a isoler plusieurs sources acoustiques puis a estimer leurs differences de temps d'arrivee entre microphones. Le pipeline s'appuie d'abord sur une selection de bins dans le plan temps-frequence, afin de ne conserver que les zones contenant du signal exploitable. La partie principale du rapport porte ensuite sur l'algorithme de separation de sources implemente dans le module **BSS**. Cette methode modelise chaque bin actif comme un coefficient complexe de source multiplie par un vecteur spatial de retards, applique un clustering EM independant par frequence, puis resout le probleme de permutation entre frequences par un RANSAC circulaire sur les phases relatives des centroïdes. Enfin, les sources separees ou les bins isoles peuvent etre utilises pour estimer les TDOA, notamment via des methodes de beamforming masquees ou ponderees.

Table des matières

1	Introduction	3
2	Creation d'un masque temps-frequence	3
2.1	Representation temps-frequence multicanale	3
2.2	Utilisation d'un reseau de neurones pour la selection de bins pertinents	3
3	Separation de sources dans le masque temps-frequence	4
3.1	Préliminaires	4
3.1.1	Hypothese de parcimonie locale	4
3.1.2	Justification de la forme des bins	4
3.1.3	Normalisation des observations	4
3.1.4	Estimation du nombre de sources	5
3.1.5	Masque temps-frequence par default sans reseau de neuronne	6
3.2	Algorithme de SAWADA	6
3.2.1	Clustering EM par frequence	6
3.2.2	Etape E	7
3.2.3	Etape M	7
3.2.4	Construction des masques de clusters	7
3.3	Assignment des clusters à l'une des sources	8
3.3.1	Motivation	8
3.3.2	Alignement par correlation d'enveloppes	8
3.3.3	RANSAC circulaire	9
3.4	Fusion finale des masques	12
4	Calcul des TDOA a partir des bins isoles	12
4.1	Beamforming masque	12

5	Validation sur un dataset synthétique	12
5.1	Validation de la separation de sources	12
5.1.1	Creation des signaux synthetiques	12
5.1.2	Evaluation de la separation	13
5.1.3	Source d'erreurs	17
5.2	Validation du beamforming	17
6	Conclusion	19
A	Demonstrations des mises a jour EM	19
A.1	Mise a jour des poids	19
A.2	Mise a jour du centroïde	20
A.3	Mise a jour de la variance	21

1 Introduction

L'estimation de la position ou de la direction d'une source acoustique dans un milieu naturel repose souvent sur l'exploitation d'un reseau de microphones. Si une source emit un signal, celui-ci est observe par chaque microphone avec un retard et une attenuation qui dependent de la geometrie de propagation. Les differences de temps d'arrivee, ou TDOA pour *Time Difference Of Arrival*, contiennent donc une information spatiale directement liee a la source.

Dans un contexte realiste, plusieurs sources peuvent etre actives simultanement, et le signal observe est un melange de contributions utiles et de bruits. Le probleme consiste alors a isoler les composantes associees a chaque source avant d'estimer leurs retards respectifs. Le pipeline considere dans ce rapport est organise en trois etapes principales :

1. construire un masque temps-frequence afin de selectionner les bins ou du signal est present ;
2. separer les sources a l'interieur de ces bins actifs ;
3. calculer les TDOA a partir des bins isolees, en particulier par beamforming.

La contribution principale de ce rapport concerne la deuxieme etape. Elle correspond au module de separation de sources present dans BSS, et plus precisement a l'algorithme de type Sawada/LOST implemente dans `BSS/Algo_Separation/Sawada_separation.py`. Cette methode exploite la structure spatiale des coefficients de STFT multicanaux : dans une zone temps-frequence locale, un bin actif est souvent domine par une seule source. Les observations associees a une meme source forment alors des directions complexes coherentes dans l'espace des microphones.

2 Creation d'un masque temps-frequence

2.1 Representation temps-frequence multicanale

On note $x_m[n]$ le signal temporel observe par le microphone m , avec $m \in \{1, \dots, M\}$. Pour chaque microphone, une transformee de Fourier a court terme est calculee :

$$X_m(f, t) = \text{STFT}\{x_m[n]\}(f, t),$$

ou f designe l'indice de frequence et t l'indice de trame temporelle.

Les observations multicanales sont ensuite regroupees sous forme vectorielle :

$$\mathbf{x}_{f,t} = \begin{bmatrix} X_1(f, t) & X_2(f, t) & \dots & X_M(f, t) \end{bmatrix}^\top \in \mathbb{C}^M.$$

Cette representation est centrale pour le pipeline. L'amplitude des coefficients permet d'identifier les zones temps-frequence contenant de l'energie utile. La phase relative entre les microphones permet quant a elle d'exploiter la geometrie de propagation et donc de distinguer les sources.

Le masque temps-frequence a pour objectif de selectionner les bins (f, t) qui contiennent du signal utile. Cette etape reduit le nombre d'observations traitees par l'algorithme de separation et limite l'influence des bins domines par le bruit.

Dans la suite, le masque utilise par default dans l'algorithme de separation est decrit dans la partie consacree aux preliminaires de Sawada. On peut egalement penser a utiliser des filtres plus developpes, voire un CNN. Cela mene a une seconde approche.

2.2 Utilisation d'un reseau de neurones pour la selection de bins pertinents

Fait par AMINE Cette approche nous permet de nous limiter aux bins contenant du signal de Beluga, enlevant ainsi du bruits ainsi que les bins du signal d'un bateau par exemple.

3 Separation de sources dans le masque temps-frequence

3.1 Préliminaires

3.1.1 Hypothese de parcimonie locale

L'algorithme de separation repose sur une hypothese de parcimonie temps-frequence. Dans une zone locale du plan temps-frequence, un bin actif est souvent domine par une seule source. Pour une source k , on peut alors ecrire :

$$\mathbf{x}_{f,t} \simeq s_k(f, t) \mathbf{a}_k(f),$$

ou $s_k(f, t) \in \mathbb{C}$ est le coefficient complexe de la source et $\mathbf{a}_k(f) \in \mathbb{C}^M$ est le vecteur spatial associe a cette source.

Le probleme de separation devient donc un probleme de regroupement de directions complexes. A frequence fixee, les bins domines par la meme source doivent se regrouper autour d'un meme vecteur spatial.

3.1.2 Justification de la forme des bins

On suppose que la propagation d'une source k vers un microphone m peut etre approximativement decrite par un gain $\rho_{m,k}$ et un retard $\tau_{m,k}$. Dans le domaine frequentiel, un retard temporel se traduit par une phase lineaire en frequence :

$$X_m(f, t) \simeq \rho_{m,k} e^{-j2\pi f \tau_{m,k}} S_k(f, t).$$

En empilant les observations de tous les microphones, on obtient :

$$\mathbf{x}_{f,t} \simeq S_k(f, t) \begin{bmatrix} \rho_{1,k} e^{-j2\pi f \tau_{1,k}} \\ \rho_{2,k} e^{-j2\pi f \tau_{2,k}} \\ \vdots \\ \rho_{M,k} e^{-j2\pi f \tau_{M,k}} \end{bmatrix} = S_k(f, t) \mathbf{a}_k(f).$$

Cette equation justifie la forme utilisee par l'algorithme : un bin est modelise comme un coefficient complexe scalaire, propre au contenu de la source, multiplie par un vecteur complexe qui encode la signature spatiale. Cette signature contient en particulier les retards relatifs entre microphones. De plus, comme les micros sont proches, on peut negliger les differences d'amplitude entre les microphones. (et surtout ne pas s'appuyer dessus pour l'algorithme)

3.1.3 Normalisation des observations

L'algorithme cherche principalement a separer les directions spatiales, et non les amplitudes. Les bins sont donc normalises individuellement :

$$\tilde{\mathbf{x}}_{f,t} = \frac{\mathbf{x}_{f,t}}{\|\mathbf{x}_{f,t}\|_2 + \epsilon}.$$

Apres normalisation, on obtient approximativement :

$$\tilde{\mathbf{x}}_{f,t} \approx e^{j\phi_{f,t}} \frac{\mathbf{a}_k(f)}{\|\mathbf{a}_k(f)\|_2}.$$

Le facteur $e^{j\phi_{f,t}}$ correspond a une phase globale. Il ne porte pas l'information spatiale utile, qui est contenue dans les phases relatives entre microphones. C'est pourquoi l'algorithme travaille sur des distances directionnelles invariantes a cette phase globale. On notera que l'on decide de ne pas faire de whitening sur les donnees. En effet, en faisant un clustering directionnel et en normalisant les donnees, l'impact du whitening est limite. Il est donc preferable de conserver la structure de retard dans les donnees.

3.1.4 Estimation du nombre de sources

Avant de lancer la separation, il est utile d'estimer combien de sources sont presentes dans le bloc audio considere. Cela permet déjà de renseigner ce paramètre qui est indispensable à l'algorithme de séparation de source pour le moment. Mais également de ne pas passer dans la pipeline de séparation de source si ca n'est pas nécessaire. L'idée generale est d'exploiter la dimension spatiale occupee par les observations multicanales dans le plan temps-frequence. Si plusieurs sources dominant des bins differents, les vecteurs normalises

$$\tilde{\mathbf{x}}_{f,t} = \frac{\mathbf{x}_{f,t}}{\|\mathbf{x}_{f,t}\|_2 + \epsilon}$$

ne se repartissent pas autour d'une seule direction, mais autour de plusieurs directions complexes. Le nombre de sources peut donc etre relie au rang effectif de la distribution spatiale des bins actifs.

Pour une frequence f , on ne conserve que les trames selectionnees par le masque temps-frequence. On construit ensuite la matrice de covariance directionnelle :

$$\mathbf{R}_f = \frac{1}{|\mathcal{T}_f|} \sum_{t \in \mathcal{T}_f} \tilde{\mathbf{x}}_{f,t} \tilde{\mathbf{x}}_{f,t}^H.$$

Les valeurs propres de cette matrice sont trieées par ordre decroissant :

$$\lambda_1(f) \geq \lambda_2(f) \geq \dots \geq \lambda_M(f).$$

Si une seule direction spatiale domine, seule la premiere valeur propre est importante. Si plusieurs directions independantes sont presentes, plusieurs valeurs propres restent significatives. L'estimation du nombre de sources se ramene donc a choisir combien de valeurs propres doivent etre considerees comme porteuses de signal.

Une premiere methode consiste a utiliser un seuil relatif. On compte le nombre de valeurs propres plus grandes qu'une fraction de la plus grande valeur propre :

$$\hat{K}_f = \# \{i : \lambda_i(f) > \rho \lambda_1(f)\}.$$

Cette methode est simple et rapide, mais elle depend fortement du seuil ρ . Si une source est beaucoup plus faible qu'une autre, sa valeur propre peut passer sous le seuil et ne pas etre comptee.

Une deuxieme methode repose sur le saut spectral, ou *eigengap*. On cherche un fort changement d'echelle entre deux valeurs propres consecutives :

$$r_i(f) = \frac{\lambda_i(f)}{\lambda_{i+1}(f) + \epsilon}.$$

Le nombre de sources est alors associe a l'indice du plus grand saut, si ce saut est suffisamment marque. Cette methode est pertinente lorsque les directions associees aux sources se separent nettement du sous-espace de bruit, mais elle peut devenir instable lorsque le spectre decroit progressivement.

Une troisieme methode utilise la variance expliquee. On choisit le plus petit nombre $\hat{K}_f$ tel que les $\hat{K}_f$ premieres valeurs propres expliquent une proportion fixee de l'energie spectrale totale :

$$\hat{K}_f = \min \left\{ K : \frac{\sum_{i=1}^K \lambda_i(f)}{\sum_{i=1}^M \lambda_i(f)} \geq \eta \right\}.$$

Cette methode interprete le nombre de sources comme une dimension effective : on garde assez d'axes principaux pour expliquer, par exemple, 90% de la variance directionnelle.

L'estimation est faite fréquence par fréquence, puis les estimations valides sont agrégées pour obtenir un nombre global de sources sur le bloc. Les fréquences contenant trop peu de bins actifs sont ignorées, car leur covariance est trop peu fiable. L'agregation peut être faite par médiane, par mode ou par quantile élevé afin de rester prudente lorsque certaines fréquences ne voient qu'une partie des sources.

Pour le moment, la méthode par variance expliquée semble la plus robuste dans nos essais. Elle évite de fixer un seuil directement sur une valeur propre absolue ou relative, et elle se comporte mieux lorsque l'énergie des sources est répartie de manière déséquilibrée. Cette partie pourrait toutefois être approfondie : on pourrait imaginer un estimateur plus sophistiqué.

3.1.5 Masque temps-fréquence par défaut sans réseau de neurone

Lorsque l'on ne dispose pas d'un masque fourni par un réseau de neurones, l'algorithme peut construire un masque temps-fréquence par défaut à partir de l'énergie du mélange. La STFT multicanale brute est d'abord calculée, puis l'énergie d'un bin temps-fréquence est définie par :

$$E(f, t) = \sum_{m=1}^M |X_m(f, t)|^2.$$

Cette énergie est convertie en décibels :

$$E_{\text{dB}}(f, t) = 10 \log_{10}(E(f, t) + \epsilon).$$

Le seuil d'activation est calculé relativement à un plancher d'énergie estimé par percentile :

$$\theta = \text{percentile}_p(E_{\text{dB}}) + \Delta_{\text{dB}}.$$

Un bin est conservé si :

$$E_{\text{dB}}(f, t) \geq \theta.$$

les valeurs utilisées sont typiquement un plancher au percentile 20, un seuil placé 6 dB au-dessus de ce plancher, et un minimum de 3 trames actives consécutives par fréquence.

Ensuite, un bin actif isolé ne fournit pas assez d'information locale pour stabiliser le clustering EM. L'implémentation filtre donc les activations fréquence par fréquence en conservant seulement les groupes temporels suffisamment longs. Si $L_{\min}$ désigne la longueur minimale, un segment actif n'est conservé que si :

$$\#\{t : (f, t) \text{ actif dans le segment}\} \geq L_{\min}.$$

Ce filtrage est important pour la robustesse de la séparation. En pratique, il évite que des fluctuations locales du bruit soient présentées à l'EM comme des observations fiables.

3.2 Algorithme de SAWADA

3.2.1 Clustering EM par fréquence

Pour chaque fréquence f , l'algorithme extrait les observations actives, on utilise le masque donnée par le réseau de neurones ou bien les bins les plus actifs :

$$\tilde{\mathbf{x}}_{f,t}, \quad t \in \mathcal{T}_f.$$

L'objectif est d'ajuster K clusters, où K est le nombre de sources. Chaque cluster k est représenté par trois paramètres :

- un centroïde complexe $\mathbf{a}_{f,k}$;
- une variance $\sigma_{f,k}^2$, qui mesure la dispersion autour de la direction ;
- un poids de mélange $\alpha_{f,k}$.

L'initialisation est faite par K-means sur les amplitudes des observations, puis les centroïdes sont normalisés sur la sphère unité complexe.

3.2.2 Etape E

L'étape E calcule, pour chaque observation, la probabilité postérieure d'appartenir à chaque cluster. La distance directionnelle utilisée est :

$$d_{k,t}^2 = 1 - \left| \mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t} \right|^2.$$

Cette distance est faible lorsque l'observation est proche de la direction du centroïde, indépendamment d'une phase globale. La probabilité non normalisée associée au cluster k est :

$$q_{k,t} = \alpha_{f,k} \frac{1}{\left(\pi(\sigma_{f,k}^2 + \epsilon) \right)^{M-1}} \exp \left(-\frac{d_{k,t}^2}{\sigma_{f,k}^2 + \epsilon} \right).$$

Les responsabilités EM sont ensuite obtenues par normalisation :

$$\gamma_{k,t} = \frac{q_{k,t}}{\sum_{\ell=1}^K q_{\ell,t} + \epsilon}.$$

3.2.3 Etape M

L'étape M met à jour les paramètres des clusters à partir des responsabilités. Les poids de mélange sont mis à jour avec un prior de Dirichlet ϕ :

$$\alpha_{f,k} = \frac{\sum_t \gamma_{k,t} + \phi}{N_f + K\phi},$$

où N_f est le nombre d'observations actives à la fréquence f .

Le centroïde est estimé comme la direction principale de la matrice de corrélation pondérée :

$$\mathbf{R}_{f,k} = \sum_t \gamma_{k,t} \tilde{\mathbf{x}}_{f,t} \tilde{\mathbf{x}}_{f,t}^H.$$

Le nouveau centroïde $\mathbf{a}_{f,k}$ est le vecteur propre principal de $\mathbf{R}_{f,k}$. La variance est ensuite mise à jour comme la dispersion moyenne pondérée des observations autour de cette direction :

$$\sigma_{f,k}^2 = \frac{\sum_t \gamma_{k,t} \left(1 - \left| \mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t} \right|^2 \right)}{(M-1) \sum_t \gamma_{k,t}}.$$

Les démonstrations détaillées de ces trois mises à jour sont données en annexe A.

En pratique, ces deux étapes sont alternées un nombre fixe de fois. Dans notre cas, pour 20 itérations, cela fonctionne bien en pratique.

3.2.4 Construction des masques de clusters

Après convergence de l'EM, un masque binaire est construit par décision dure. Pour chaque bin actif, on choisit le cluster avec le plus grand score :

$$\hat{k}(f, t) = \arg \max_k \frac{\left| \mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t} \right|^2}{\sigma_{f,k}^2 + \epsilon}.$$

Le masque du cluster k est alors :

$$M_k(f, t) = \begin{cases} 1 & \text{si } \hat{k}(f, t) = k, \\ 0 & \text{sinon.} \end{cases}$$

À ce stade, les masques sont cohérents localement à une fréquence donnée, mais pas encore globalement entre fréquences. Comme l'EM est lancé indépendamment pour chaque fréquence, le cluster numéroté 0 à une fréquence peut correspondre à une autre source que le cluster numéroté 0 à la fréquence suivante. C'est le problème classique de permutation.

3.3 Assignment des clusters à l'une des sources

3.3.1 Motivation

Pour reconstruire une source, il faut que les masques soient cohérents sur toutes les fréquences. L'implémentation propose deux stratégies d'alignement : une méthode par corrélation d'enveloppes, et une méthode par RANSAC circulaire. La configuration de benchmark utilise l'alignement par RANSAC, car il exploite directement la structure physique des phases relatives.

3.3.2 Alignement par corrélation d'enveloppes

L'assignation par corrélation d'enveloppes consiste à associer, pour chaque fréquence, les clusters locaux aux sources globales déjà suivies aux fréquences précédentes. Pour ce faire, on calcule l'enveloppe $e_k^f(t)$ du cluster k à la fréquence f :

$$e_k^f(t) = \sum_m |X_m(f, t)|^2 M_k(f, t)$$

où $M_k(f, t)$ est le masque binaire du cluster k pour la fréquence f .

On calcule ensuite pour chaque combinaison d'attribution possible

$$\pi \in \mathfrak{S}_K$$

un score de cohérence entre les enveloppes du bin courant et les enveloppes de référence déjà associées aux sources. Si $r_s^{f-1}(t)$ désigne l'enveloppe de référence de la source s construite à partir des fréquences précédentes, le score de la permutation π est :

$$C_f(\pi) = \sum_{s=1}^K \rho \left(e_{\pi(s)}^f(t), r_s^{f-1}(t) \right),$$

ou $\rho(\cdot, \cdot)$ est la corrélation de Pearson :

$$\rho(u, v) = \frac{\sum_t (u(t) - \bar{u})(v(t) - \bar{v})}{\sqrt{\sum_t (u(t) - \bar{u})^2} \sqrt{\sum_t (v(t) - \bar{v})^2} + \epsilon}.$$

La permutation retenue est celle qui maximise cette corrélation totale :

$$\pi_f^* = \arg \max_{\pi \in \mathfrak{S}_K} C_f(\pi).$$

Les masques de la fréquence f sont ensuite reordonnés selon π_f^* :

$$M_s(f, t) \leftarrow M_{\pi_f^*(s)}(f, t).$$

L'enveloppe de référence est finalement mise à jour de façon progressive. Dans le mode `ema` utilisé par l'implémentation, cette mise à jour prend la forme :

$$r_s^f(t) = (1 - \beta) r_s^{f-1}(t) + \beta e_{\pi_f^*(s)}^f(t),$$

avec $\beta = 0.1$ dans le code. Une fréquence dont l'énergie associée à une source est trop faible ne met pas à jour la référence, afin d'éviter qu'un bin peu informatif dégrade l'alignement des fréquences suivantes.

Cette méthode est simple et ne suppose pas explicitement un modèle de retard. Elle utilise seulement la similarité temporelle des enveloppes : deux clusters appartenant à la même source doivent présenter des activations temporelles corrélées d'une fréquence à l'autre. En revanche, cette méthode ordonne les fréquences car les basses fréquences servent initialement à construire l'enveloppe de référence. Aussi, beaucoup de situation, notamment lors de vocalise simultané, peuvent donner lieu à des erreurs.

3.3.3 RANSAC circulaire

conversion des centroides en phase relative

Les centroïdes complexes $\mathbf{a}_{f,k}$ contiennent une phase globale arbitraire. Pour la supprimer, on choisit un microphone de reference, note ici 1, et on calcule :

$$z_{f,k,m}^{\text{rel}} = a_{f,k,m} a_{f,k,1}^*.$$

La phase relative associee est :

$$\theta_{f,k,m} = \arg \left(z_{f,k,m}^{\text{rel}} \right).$$

Si le centroïde correspond a une source physique dominee par des retards, alors on attend une relation de la forme :

$$\theta_{f,k,m} \approx b_m - 2\pi f(\tau_m - \tau_1) \pmod{2\pi}.$$

Les phases relatives d'une meme source decrivent donc une droite en frequence, mais observee modulo 2π . Cette propriete est la base du RANSAC circulaire implemente dans `BSS/CircularRansac`.

Remarque : si l'on a precedemment blanchis le données, il faut penser à faire l'opération inverse sur les centroides au risque de faire un ransac sur des données qui ne représente aucunement des droites

Modele ajusté par RANSAC circulaire

Le modele ajuste est une droite circulaire multidimensionnelle :

$$\boldsymbol{\theta}_i = \mathbf{b} + (f_i - f_{\text{ref}})\mathbf{v} \pmod{2\pi}.$$

La distance d'une observation au modele est calculee apres repliement de phase :

$$d_i = \|\text{wrap}(\boldsymbol{\theta}_i - \mathbf{b} - (f_i - f_{\text{ref}})\mathbf{v})\|_2.$$

Concretement, chaque observation donnee au RANSAC correspond a un centroïde disponible a une frequence donnee. Elle est decrite par sa frequence f_i et par son vecteur de phases relatives :

$$\boldsymbol{\theta}_i = [\theta_{i,1} \quad \cdots \quad \theta_{i,M}]^\top.$$

Le RANSAC construit d'abord des hypotheses de trajectoires a partir de petits echantillons d'observations, typiquement deux centroïdes pris a deux frequences distinctes. Pour une paire (i, j) , la pente candidate doit verifier :

$$\boldsymbol{\theta}_j - \boldsymbol{\theta}_i = (f_j - f_i)\mathbf{v} \pmod{2\pi}.$$

Comme les phases sont definies modulo 2π , plusieurs pentes peuvent expliquer la meme paire d'observations :

$$\mathbf{v} = \frac{\boldsymbol{\theta}_j - \boldsymbol{\theta}_i + 2\pi\mathbf{n}}{f_j - f_i}, \quad \mathbf{n} \in \mathbb{Z}^M.$$

L'implementation enumere les hypotheses compatibles avec les bornes physiques sur la pente. Ces bornes proviennent du retard maximal possible entre microphones : comme $v_m = -2\pi\tau_m$, limiter les TDOA revient a limiter les pentes admissibles.

Pour chaque hypothese $(\mathbf{b}, \mathbf{v})$, l'algorithme calcule la distance circulaire de toutes les observations au modele. Une observation est consideree comme un inlier si :

$$d_i < \eta,$$

ou η est le seuil de residu circulaire. Le score utilise est de type MSAC : au lieu de compter seulement les inliers, on somme des residus tronques :

$$S = \sum_i \min(d_i^2, \eta^2).$$

Le meilleur modele est celui qui minimise ce score. Apres selection d'une bonne hypothese, une optimisation locale raffine la pente et l'intercept sur les inliers. Pour une pente fixee, l'intercept optimal est obtenu par moyenne circulaire des phases residuelles :

$$b_m(\mathbf{v}) = \arg \sum_{i \in \mathcal{I}} \exp(j(\theta_{i,m} - (f_i - f_{\text{ref}})v_m)),$$

ou $\mathcal{I}$ designe l'ensemble des inliers.

Comme il y a plusieurs sources, l'extraction est sequentielle. Le RANSAC trouve d'abord la trajectoire la plus coherente, associe les centroïdes compatibles a cette source, puis retire ou marque ces centroïdes avant de chercher la trajectoire suivante. Cette procedure est repetee jusqu'a obtenir K trajectoires, c'est-a-dire une trajectoire de phase par source attendue.

Enfin, tous les centroïdes disponibles sont assignes a la trajectoire la plus proche. Les centroïdes trop eloignes de toutes les trajectoires peuvent etre marques comme non assignes. Les labels obtenus permettent ensuite de fusionner les masques de clusters en masques de sources coherents sur l'ensemble des frequences.

Lien entre pente de phase et TDOA

La pente estimee pour le microphone m a une interpretation directe :

$$v_m = -2\pi(\tau_m - \tau_{\text{ref}}).$$

Le retard relatif au microphone de reference est donc :

$$\tau_m - \tau_{\text{ref}} = -\frac{v_m}{2\pi}.$$

Les TDOA entre paires de microphones sont ensuite calcules par difference :

$$\Delta\tau_{i,j} = \tau_j - \tau_i.$$

En revanche, les tdoas estimé à partir de la pente recupérée dans le RANSAC sont souvent mauvais en comparaison des autres methodes. Cela est donc utile à améliorer la cohérence des mask mais ne sert pas directement au calcul de TDOAS. Il servent principalement à verifier que l'on ne s'est pas totalement trompé. On peut visualiser l'attribution des centroides et la droite trouvé par le RANSAC figure 1

Merge automatique de cluster

Dans le cas ou une fréquence ne contient pas toute les sources, la méthode par corrélation sépare artificiellement les bins de la fréquence. La méthode RANSAC permet quant à elle d'attribuer à plusieurs cluster d'une meme fréquence la même source. Comme montré figure 2, les deux clusters collé sont finalement attribué à une seule et meme source.




FIGURE 1 – Argument de la composante i en fonction de la fréquence du centroïde




FIGURE 2 – Merge automatique de clusters : comparaison entre l'attribution initiale des clusters et l'attribution après RANSAC.

3.4 Fusion finale des masques

Une fois les centroïdes associes a des sources, les masques de clusters sont fusionnes. Pour une source s , le masque final est :

$$M_s(f, t) = \sum_{k: \text{label}(f, k)=s} M_k(f, t).$$

Une fois les masques de sources obtenus, on reconstruit d'abord, pour chaque source s , une STFT multicanale masquee. Si $\mathbf{X}(f, t)$ designe la STFT du melange original et $M_s(f, t)$ le masque associe a la source s , on calcule :

$$\hat{\mathbf{X}}_s(f, t) = M_s(f, t) \mathbf{X}(f, t).$$

Le meme masque est applique a tous les microphones. On conserve ainsi les bins temps-frequence attribues a la source s , tout en gardant les differences de phase entre microphones presentes dans la STFT originale.

On applique ensuite une STFT inverse a chaque canal de $\hat{\mathbf{X}}_s(f, t)$ afin d'obtenir une reconstruction temporelle multicanale :

$$\hat{\mathbf{x}}_s[n] = \text{iSTFT} \left(\hat{\mathbf{X}}_s(f, t) \right).$$

Les TDOA peuvent alors etre estimes sur ces signaux temporels reconstruits. Cette methode n'a pas de garantie theorique forte. En effet, une STFT masquee bin par bin ne correspond pas necessairement a la STFT exacte d'un signal physique reel : le masquage peut introduire des incoherences entre trames et entre frequences. La reconstruction par iSTFT doit donc etre vue comme un signal ayant une STFT proche de la STFT masquee du signal original, pas comme une reconstruction parfaite de la source originale.

Malgre cette limite, l'approche fonctionne relativement bien en pratique sur le benchmark. Elle fournit une premiere estimation simple des TDOA, directement exploitable apres la separation. Sa qualite depend principalement de la qualite du masque final : une erreur de separation ou d'assignation de clusters peut deteriorer les signaux reconstruits, et donc les retards estimes par correlation.

4 Calcul des TDOA a partir des bins isoles

4.1 Beamforming masque

Partie faite par AMINE

5 Validation sur un dataset synthétique

5.1 Validation de la separation de sources

5.1.1 Creation des signaux synthetiques

La validation de la separation repose sur des scenes synthetiques pour lesquelles on connait les sources originales et les retards appliques sur chaque microphone. Une scene est construite en generant d'abord plusieurs signaux monophoniques representant les sources acoustiques d'interet, puis en les placant dans le temps avec un gain et une fenetre d'apparition. Ces sources sont ensuite propagees vers les microphones par un modele de melange a retards.

Pour modeliser les vocalisations de belugas, on utilise un signal de type sifflement harmonique a frequence instantanee variable. On definit d'abord un contour frequenciel fondamental $f_0(t)$, obtenu a partir de quelques points de controle relies par une interpolation lisse. Ce contour peut

monter ou descendre au cours du temps, avec des changements de direction aleatoires, puis un faible jitter temporellement correle est ajoute :

$$f_{\text{inst}}(t) = \text{clip}(f_0(t) + \eta(t), f_{\min}, f_{\max}).$$

La phase instantanee du sifflement est obtenue par integration de cette frequence :

$$\varphi(t) = 2\pi \int_0^t f_{\text{inst}}(u) du.$$

En temps discret, cette integration est implementee sous forme cumulative :

$$\varphi[n] = \frac{2\pi}{f_s} \sum_{\ell=0}^n f_{\text{inst}}[\ell].$$

Le signal de beluga est ensuite construit comme une somme d'harmoniques de cette phase :

$$s[n] = A[n] \sum_{h=1}^H a_h \sin(h\varphi[n] + \psi_h),$$

ou a_h est l'amplitude de l'harmonique h , ψ_h sa phase initiale et $A[n]$ une enveloppe lente. Les amplitudes harmoniques decroissent globalement avec l'ordre harmonique, avec une petite variation aleatoire, ce qui produit des sifflements spectraux plausibles sans rendre toutes les realisations identiques.

Le melange multicanal est ensuite obtenu en appliquant un retard entier $d_{m,k}$ entre la source k et le microphone m :

$$x_m[n] = \sum_{k=1}^K g_{m,k} s_k[n - d_{m,k}] + b_m[n],$$

ou $g_{m,k}$ represente un gain eventuel et $b_m[n]$ regroupe les bruits ajoutes au microphone m qui peuvent etre gaussien ou bien impulsifs. Les retards $d_{m,k}$ etant connus, les TDOA de reference sont directement disponibles :

$$\Delta\tau_{i,j,k}^{\text{ref}} = \frac{d_{j,k} - d_{i,k}}{f_s}.$$

Ce cadre synthetique permet donc de tester la separation dans une situation ou l'on connait a la fois les sources propres, le melange observe et la solution spatiale attendue. Aussi, la forme des signaux choisis nous permet d'avoir un signal ressemblant à un whistle et qui n'a pas une fréquence fixe tout en ayant une certaine continuité en fréquence.

5.1.2 Evaluation de la separation

Résultats qualitatifs

La figure 3 illustre d'abord les resultats de separation dans le plan temps-frequence. Elle permet de verifier visuellement que les bins actifs sont bien repartis entre les sources estimees et que les masques obtenus suivent les structures spectrales principales du melange. D'un point de vue qualitatif, la separation est relativement bonne. On rajoute ensuite du bruit sur le melange pour un snr qui varie entre 0 et 10 dB. La figure 4 illustre les resultats obtenus.

Résultats quantitatifs

La figure 5 donne ensuite une analyse plus quantitative, en comparant les TDOA obtenus a partir des sources reconstruites (donc une methode basique qui n'est pas suppose donner des resultats parfaits comme vu sur la partie 3.4). Cette visualisation permet d'evaluer si la separation conserve suffisamment la coherence temporelle entre microphones pour fournir une premiere estimation fiable des retards. De meme, on trace les TDOA obtenus dans la situation avec bruit. figure 6




FIGURE 3 – Resultats de separation de sources dans le plan temps-frequence. à gauche la source 1 et 2, au milieu le melange et à droite la source estimé 1 et 2.




FIGURE 4 – Resultats de separation de sources dans le plan temps-frequence avec bruit. à gauche la source 1 et 2, au milieu le melange et à droite la source estimé 1 et 2.




FIGURE 5 – Analyse quantitative des TDOA estimates par correlation sur les sources separees.




FIGURE 6 – Analyse quantitative des TDOA estimates par correlation sur les sources separees.

5.1.3 Source d'erreurs

Comme nous l'avons vu, les résultats ne sont pas parfait non plus. Il y a plusieurs source d'erreurs que l'on essaie d'explorer ici.

Mauvaise estimations des bins ayant du signal quand il y a du bruit

On a ici utilisé la méthode décrite dans la partie 3.1.5. Cela fonctionne bien sans bruit mais est bien trop approximatif avec bruit, comme on peut le voir figure 7. Cela motive donc l'utilisation d'un réseau de neurone pour cette tâche qui s'apprend bien mais reste loin d'être triviale




FIGURE 7 – Comparaison de l'estimation des bins contenant du signal par seuillage d'énergie, sans bruit et avec bruit.

Mauvaise droite dans le RANSAC

Dans le cas sans bruit, l'extrait numéro 14 ne fonctionne pas. figure 5.1.3. En regardant en détails, on remarque en fait que certains bins ayant du signal ne sont attribués à aucune des deux sources. Un exemple sont les bins centraux de la fréquence 2250. En regardant ce qui se passe au niveau du clustering figure 5.1.3, on remarque que celui-ci se passe correctement, distinguant les points aux extrémité des points centraux. On regarde alors au niveau du RANSAC figure 5.1.3. En comparaison avec les droite "Ground Truth", les deux droites trouvés par RANSAC correspondent en réalité à la meme ground truth. Ainsi, la seconde droite est totalement ignoré. Cela n'arrive pas souvent que ca soit sans bruit ou avec bruit mais peut tout de meme arrivé. Augmenter le nombre d'itération du RANSAC peut améliorer cela.






FIGURE 8 – Extrait 14 : mélange et sources de reference.

5.2 Validation du beamforming

La seconde validation concerne l'utilisation des bins isolés pour le beamforming. L'objectif n'est plus seulement de reconstruire les sources, mais d'utiliser les masques temps-fréquence




Clusters obtenus.




Clusters attribues.

FIGURE 9 – Extrait 14 : clusters avant et apres attribution.



Attribution de reference.



Droite estimee par RANSAC.

FIGURE 10 – Extrait 14 : comparaison entre la reference et la droite estimee par RANSAC.

pour guider une methode d'estimation spatiale. Les bins selectionnes par le masque peuvent etre utilises comme poids ou comme zones d'interet dans le calcul du pseudo-spectre.

On compare alors les directions ou TDOA obtenus par beamforming masque aux valeurs de reference disponibles dans le dataset. Cette validation permet d'evaluer si la separation temps-frequence ameliore effectivement l'estimation spatiale, en reduisant l'influence des bins domines par le bruit ou par les autres sources.

6 Conclusion

L'algorithme de separation etudie exploite la structure physique des signaux multicanaux dans le domaine temps-frequence. Sous l'hypothese qu'un bin actif est localement domine par une source, l'observation multicanaux peut etre modelisee comme un coefficient complexe multiplie par un vecteur spatial de retards. Cette structure permet de transformer le probleme de separation en un probleme de clustering de directions complexes.

Le clustering EM estime, pour chaque frequence, des centroïdes correspondant aux signatures spatiales locales des sources. Le RANSAC circulaire resout ensuite le probleme de permutation entre frequences en cherchant des trajectoires de phase compatibles avec des retards physiques. Les masques finaux permettent de reconstruire les sources et de calculer des TDOA, soit par correlation sur les signaux reconstruits, soit a partir des pentes de phase, soit encore en alimentant un beamformer masque.

La validation sur dataset synthetique fournit un cadre reproductible pour mesurer les erreurs de TDOA et inspecter les artefacts internes de l'algorithme. Les prochaines etapes naturelles consistent a completer les resultats quantitatifs, etudier la sensibilite aux niveaux de bruit et comparer systematiquement l'apport du masque temps-frequence dans la qualite finale de la separation et des TDOA.

A Demonstrations des mises a jour EM

Dans l'algorithme de Sawada, l'etape M consiste a maximiser l'esperance de la log-vraisemblance complete par rapport aux parametres de chaque source. Pour une frequence donnee, on note $\mathcal{X} = \{\tilde{\mathbf{x}}_t\}_{t=1}^T$ l'ensemble des observations normalisees, avec $\|\tilde{\mathbf{x}}_t\|_2 = 1$. Pour une source i , les parametres sont le centroïde $\mathbf{a}_i$, contraint par $\|\mathbf{a}_i\|_2 = 1$, la variance σ_i^2 et le poids de melange α_i .

La quantite maximisee par l'EM est :

$$Q = \sum_{t=1}^T \sum_{i=1}^K \gamma_{i,t} \left[\ln(\alpha_i) + \ln p(\tilde{\mathbf{x}}_t | \mathbf{a}_i, \sigma_i^2) \right].$$

A.1 Mise a jour des poids

Sans regularisation, la mise a jour des poids maximise :

$$\sum_{i=1}^K \sum_{t=1}^T \gamma_{i,t} \ln(\alpha_i) \quad \text{sous la contrainte} \quad \sum_{i=1}^K \alpha_i = 1.$$

En utilisant un multiplicateur de Lagrange λ , on derive :

$$\frac{\partial}{\partial \alpha_i} \left(\sum_{i,t} \gamma_{i,t} \ln(\alpha_i) - \lambda \sum_i \alpha_i \right) = \frac{\sum_t \gamma_{i,t}}{\alpha_i} - \lambda = 0.$$

On obtient donc :

$$\alpha_i = \frac{\sum_t \gamma_{i,t}}{\lambda}.$$

Puisque $\sum_i \alpha_i = 1$, on a :

$$\lambda = \sum_i \sum_t \gamma_{i,t} = T.$$

D’ou :

$$\alpha_i = \frac{\sum_t \gamma_{i,t}}{T}.$$

L’ajout de ϕ dans le code correspond a l’introduction d’un prior de Dirichlet pour regulariser l’estimation. Dans ce cas, la mise a jour devient :

$$\alpha_i = \frac{\sum_t \gamma_{i,t} + \phi}{T + K\phi}.$$

A.2 Mise a jour du centroïde

Le terme de la log-vraisemblance dependant du centroïde $\mathbf{a}_i$ est :

$$Q(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \left(-\frac{\left\| \tilde{\mathbf{x}}_t - \left(\mathbf{a}_i^H \tilde{\mathbf{x}}_t \right) \mathbf{a}_i \right\|_2^2}{\sigma_i^2} \right).$$

Puisque $\|\tilde{\mathbf{x}}_t\|_2 = 1$ et $\|\mathbf{a}_i\|_2 = 1$, la distance a la projection verifie :

$$\left\| \tilde{\mathbf{x}}_t - \left(\mathbf{a}_i^H \tilde{\mathbf{x}}_t \right) \mathbf{a}_i \right\|_2^2 = 1 - \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2.$$

Maximiser $Q(\mathbf{a}_i)$ revient donc a maximiser :

$$\mathcal{J}(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2.$$

Cette quantite peut s’ecrire sous forme quadratique :

$$\mathcal{J}(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \mathbf{a}_i^H \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H \mathbf{a}_i = \mathbf{a}_i^H \left(\sum_{t=1}^T \gamma_{i,t} \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H \right) \mathbf{a}_i.$$

En posant :

$$\mathbf{R}_i = \sum_{t=1}^T \gamma_{i,t} \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H,$$

on cherche :

$$\max_{\mathbf{a}_i} \mathbf{a}_i^H \mathbf{R}_i \mathbf{a}_i \quad \text{sous la contrainte} \quad \mathbf{a}_i^H \mathbf{a}_i = 1.$$

Par la methode des multiplicateurs de Lagrange, on maximise :

$$\mathcal{L} = \mathbf{a}_i^H \mathbf{R}_i \mathbf{a}_i - \lambda \left(\mathbf{a}_i^H \mathbf{a}_i - 1 \right).$$

La condition d’optimalite donne :

$$\mathbf{R}_i \mathbf{a}_i = \lambda \mathbf{a}_i.$$

Le maximum est donc atteint pour le vecteur propre associe a la plus grande valeur propre de $\mathbf{R}_i$. C’est cette operation qui est calculee par la decomposition en valeurs propres dans l’implementation.

A.3 Mise a jour de la variance

La densite de probabilite sur l'hypersphere complexe de dimension M est proportionnelle a :

$$p(\tilde{\mathbf{x}}_t \mid \mathbf{a}_i, \sigma_i^2) = \frac{1}{(\pi\sigma_i^2)^{M-1}} \exp\left(-\frac{1 - |\mathbf{a}_i^H \tilde{\mathbf{x}}_t|^2}{\sigma_i^2}\right).$$

En posant :

$$d_{i,t}^2 = 1 - |\mathbf{a}_i^H \tilde{\mathbf{x}}_t|^2,$$

le terme de Q dependant de σ_i^2 s'ecrit :

$$Q(\sigma_i^2) = \sum_{t=1}^T \gamma_{i,t} \left[-(M-1) \ln(\sigma_i^2) - \frac{d_{i,t}^2}{\sigma_i^2} \right].$$

On derive ensuite par rapport a σ_i^2 :

$$\frac{\partial Q}{\partial \sigma_i^2} = -\frac{(M-1) \sum_t \gamma_{i,t}}{\sigma_i^2} + \frac{\sum_t \gamma_{i,t} d_{i,t}^2}{(\sigma_i^2)^2}.$$

En annulant cette derivee, on obtient :

$$(M-1)\sigma_i^2 \sum_t \gamma_{i,t} = \sum_t \gamma_{i,t} d_{i,t}^2.$$

D'ou :

$$\sigma_i^2 = \frac{\sum_t \gamma_{i,t} d_{i,t}^2}{(M-1) \sum_t \gamma_{i,t}}.$$