

Rapport sur un algorithme de separation de sources acoustiques

A completer

25 août 2026

Résumé

Ce rapport decrit un pipeline de traitement audio multicanal destine a isoler plusieurs sources acoustiques puis a estimer leurs differences de temps d'arrivee entre microphones. Le pipeline s'appuie d'abord sur une selection de bins dans le plan temps-frequence, afin de ne conserver que les zones contenant du signal exploitable. La partie principale du rapport porte ensuite sur l'algorithme de separation de sources. Cette methode modelise chaque bin actif comme un coefficient complexe de source multiplie par un vecteur spatial de retards, applique un clustering EM independant par frequence, puis resout le probleme de permutation entre frequences par un RANSAC circulaire sur les phases relatives des centroïdes. Enfin, les sources separees ou les bins isoles peuvent etre utilises pour estimer les TDOA, notamment via des methodes de beamforming masquees ou ponderees.

Table des matières

1	Introduction	3
2	Creation d'un masque temps-frequence	3
2.1	Representation temps-frequence multicanale	3
2.2	Utilisation d'un reseau de neurones pour la selection de bins pertinents	3
3	Separation de sources dans le masque temps-frequence	4
3.1	Préliminaires	4
3.1.1	Hypothese de parcimonie locale	4
3.1.2	Justification de la forme des bins	4
3.1.3	Normalisation des observations	4
3.1.4	Estimation du nombre de sources	5
3.1.5	Masque temps-frequence par default sans reseau de neurones	6
3.2	Algorithme de SAWADA	6
3.2.1	Clustering EM par frequence	6
3.2.2	Etape E	7
3.2.3	Etape M	7
3.2.4	Construction des masques de clusters	7
3.3	Assignation des clusters à l'une des sources	8
3.3.1	Motivation	8
3.3.2	Alignement par correlation d'enveloppes	8
3.3.3	RANSAC circulaire	9
3.4	Fusion finale des masques	12
4	Calcul des TDOA a partir des bins isoles	12
4.1	Beamforming masque	12

5	Validation sur un dataset synthétique	12
5.1	Validation de la separation de sources	12
5.1.1	Creation des signaux synthetiques	12
5.1.2	Evaluation de la separation	13
5.1.3	Source d'erreurs	17
5.2	Validation du beamforming	18
6	Analyse des donnees 2026	19
6.1	Introduction	19
6.2	Comparaison des differentes methodes d'estimation de position	23
6.3	Point ne fonctionnant pas bien	25
6.3.1	Point numero 8 : bateau	25
6.3.2	Point 14 à 20 : biais apparent	25
7	Conclusion	28
A	Demonstrations des mises a jour EM	29
A.1	Mise a jour des poids	29
A.2	Mise a jour du centroïde	30
A.3	Mise a jour de la variance	30

1 Introduction

L'estimation de la position ou de la direction d'une source acoustique dans un milieu naturel repose souvent sur l'exploitation d'un reseau de microphones. Si une source emit un signal, celui-ci est observe par chaque microphone avec un retard et une attenuation qui dependent de la geometrie de propagation. Les differences de temps d'arrivee, ou TDOA pour *Time Difference Of Arrival*, contiennent donc une information spatiale directement liee a la source.

Dans un contexte realiste, plusieurs sources peuvent etre actives simultanement, et le signal observe est un melange de contributions utiles et de bruits. Le probleme consiste alors a isoler les composantes associees a chaque source avant d'estimer leurs retards respectifs. Le pipeline considere dans ce rapport est organise en trois etapes principales :

1. construire un masque temps-frequence afin de selectionner les bins ou du signal est present ;
2. separer les sources a l'interieur de ces bins actifs ;
3. calculer les TDOA a partir des bins isolees, en particulier par beamforming.

La contribution principale de ce rapport concerne la deuxieme etape, c'est-a-dire la separation de sources dans le plan temps-frequence. La methode etudiee s'inspire des approches de type Sawada/LOST et exploite la structure spatiale des coefficients de STFT multicanaux : dans une zone temps-frequence locale, un bin actif est souvent domine par une seule source. Les observations associees a une meme source forment alors des directions complexes coherentes dans l'espace des microphones.

2 Creation d'un masque temps-frequence

2.1 Representation temps-frequence multicanale

On note $x_m[n]$ le signal temporel observe par le microphone m , avec $m \in \{1, \dots, M\}$. Pour chaque microphone, une transformee de Fourier a court terme est calculee :

$$X_m(f, t) = \text{STFT}\{x_m[n]\}(f, t),$$

ou f designe l'indice de frequence et t l'indice de trame temporelle.

Les observations multicanales sont ensuite regroupees sous forme vectorielle :

$$\mathbf{x}_{f,t} = \begin{bmatrix} X_1(f, t) & X_2(f, t) & \cdots & X_M(f, t) \end{bmatrix}^\top \in \mathbb{C}^M.$$

Cette representation est centrale pour le pipeline. L'amplitude des coefficients permet d'identifier les zones temps-frequence contenant de l'energie utile. La phase relative entre les microphones permet quant a elle d'exploiter la geometrie de propagation et donc de distinguer les sources.

Le masque temps-frequence a pour objectif de selectionner les bins (f, t) qui contiennent du signal utile. Cette etape reduit le nombre d'observations traitees par l'algorithme de separation et limite l'influence des bins domines par le bruit.

Dans la suite, le masque utilise par default dans l'algorithme de separation est decrit dans la partie consacree aux preliminaires de Sawada. On peut egalement penser a utiliser des filtres plus developpes, voire un CNN. Cela mene a une seconde approche.

2.2 Utilisation d'un reseau de neurones pour la selection de bins pertinents

Cette partie est traitee separement. Cette approche nous permet de nous limiter aux bins contenant du signal de beluga, en supprimant une partie du bruit ainsi que certains bins correspondant, par exemple, au signal d'un bateau.

3 Separation de sources dans le masque temps-frequence

3.1 Préliminaires

3.1.1 Hypothese de parcimonie locale

L'algorithme de separation repose sur une hypothese de parcimonie temps-frequence. Dans une zone locale du plan temps-frequence, un bin actif est souvent domine par une seule source. Pour une source k , on peut alors ecrire :

$$\mathbf{x}_{f,t} \simeq s_k(f, t) \mathbf{a}_k(f),$$

ou $s_k(f, t) \in \mathbb{C}$ est le coefficient complexe de la source et $\mathbf{a}_k(f) \in \mathbb{C}^M$ est le vecteur spatial associe a cette source.

Le probleme de separation devient donc un probleme de regroupement de directions complexes. A frequence fixee, les bins domines par la meme source doivent se regrouper autour d'un meme vecteur spatial.

3.1.2 Justification de la forme des bins

On suppose que la propagation d'une source k vers un microphone m peut etre approximativement decrite par un gain $\rho_{m,k}$ et un retard $\tau_{m,k}$. Dans le domaine frequentiel, un retard temporel se traduit par une phase lineaire en frequence :

$$X_m(f, t) \simeq \rho_{m,k} e^{-j2\pi f \tau_{m,k}} S_k(f, t).$$

En empilant les observations de tous les microphones, on obtient :

$$\mathbf{x}_{f,t} \simeq S_k(f, t) \begin{bmatrix} \rho_{1,k} e^{-j2\pi f \tau_{1,k}} \\ \rho_{2,k} e^{-j2\pi f \tau_{2,k}} \\ \vdots \\ \rho_{M,k} e^{-j2\pi f \tau_{M,k}} \end{bmatrix} = S_k(f, t) \mathbf{a}_k(f).$$

Cette equation justifie la forme utilisee par l'algorithme : un bin est modelise comme un coefficient complexe scalaire, propre au contenu de la source, multiplie par un vecteur complexe qui encode la signature spatiale. Cette signature contient en particulier les retards relatifs entre microphones. De plus, comme les microphones sont proches, on peut negliger les differences d'amplitude entre les canaux et privilegier l'information de phase.

3.1.3 Normalisation des observations

L'algorithme cherche principalement a separer les directions spatiales, et non les amplitudes. Les bins sont donc normalises individuellement :

$$\tilde{\mathbf{x}}_{f,t} = \frac{\mathbf{x}_{f,t}}{\|\mathbf{x}_{f,t}\|_2 + \epsilon}.$$

Apres normalisation, on obtient approximativement :

$$\tilde{\mathbf{x}}_{f,t} \approx e^{j\phi_{f,t}} \frac{\mathbf{a}_k(f)}{\|\mathbf{a}_k(f)\|_2}.$$

Le facteur $e^{j\phi_{f,t}}$ correspond a une phase globale. Il ne porte pas l'information spatiale utile, qui est contenue dans les phases relatives entre microphones. C'est pourquoi l'algorithme travaille sur des distances directionnelles invariantes a cette phase globale. On choisit ici de ne pas blanchir les donnees. En effet, le clustering est directionnel et les observations sont deja normalisees ; l'apport du blanchiment est donc limite dans ce cadre. Il est preferable de conserver la structure de retard presente dans les observations.

3.1.4 Estimation du nombre de sources

Avant de lancer la separation, il est utile d'estimer combien de sources sont presentes dans le bloc audio considere. Cette estimation fournit un parametre important pour la separation et permet aussi d'eviter de lancer inutilement le pipeline lorsque le bloc ne contient pas de situation de melange. L'idee generale est d'exploiter la dimension spatiale occupee par les observations multicanales dans le plan temps-frequence. Si plusieurs sources dominent des bins differents, les vecteurs normalises

$$\tilde{\mathbf{x}}_{f,t} = \frac{\mathbf{x}_{f,t}}{\|\mathbf{x}_{f,t}\|_2 + \epsilon}$$

ne se repartissent pas autour d'une seule direction, mais autour de plusieurs directions complexes. Le nombre de sources peut donc etre relie au rang effectif de la distribution spatiale des bins actifs.

Pour une frequence f , on ne conserve que les trames selectionnees par le masque temps-frequence. On construit ensuite la matrice de covariance directionnelle :

$$\mathbf{R}_f = \frac{1}{|\mathcal{T}_f|} \sum_{t \in \mathcal{T}_f} \tilde{\mathbf{x}}_{f,t} \tilde{\mathbf{x}}_{f,t}^H.$$

Les valeurs propres de cette matrice sont trieess par ordre decroissant :

$$\lambda_1(f) \geq \lambda_2(f) \geq \dots \geq \lambda_M(f).$$

Si une seule direction spatiale domine, seule la premiere valeur propre est importante. Si plusieurs directions independantes sont presentes, plusieurs valeurs propres restent significatives. L'estimation du nombre de sources se ramene donc a choisir combien de valeurs propres doivent etre considerees comme porteuses de signal.

Une premiere methode consiste a utiliser un seuil relatif. On compte le nombre de valeurs propres plus grandes qu'une fraction de la plus grande valeur propre :

$$\hat{K}_f = \# \{i : \lambda_i(f) > \rho \lambda_1(f)\}.$$

Cette methode est simple et rapide, mais elle depend fortement du seuil ρ . Si une source est beaucoup plus faible qu'une autre, sa valeur propre peut passer sous le seuil et ne pas etre comptee.

Une deuxieme methode repose sur le saut spectral, ou *eigengap*. On cherche un fort changement d'echelle entre deux valeurs propres consecutives :

$$r_i(f) = \frac{\lambda_i(f)}{\lambda_{i+1}(f) + \epsilon}.$$

Le nombre de sources est alors associe a l'indice du plus grand saut, si ce saut est suffisamment marque. Cette methode est pertinente lorsque les directions associees aux sources se separent nettement du sous-espace de bruit, mais elle peut devenir instable lorsque le spectre decroit progressivement.

Une troisieme methode utilise la variance expliquee. On choisit le plus petit nombre $\hat{K}_f$ tel que les $\hat{K}_f$ premieres valeurs propres expliquent une proportion fixee de l'energie spectrale totale :

$$\hat{K}_f = \min \left\{ K : \frac{\sum_{i=1}^K \lambda_i(f)}{\sum_{i=1}^M \lambda_i(f)} \geq \eta \right\}.$$

Cette methode interprete le nombre de sources comme une dimension effective : on garde assez d'axes principaux pour expliquer, par exemple, 90% de la variance directionnelle.

L'estimation est faite frequence par frequence, puis les estimations valides sont agregees pour obtenir un nombre global de sources sur le bloc. Les frequences contenant trop peu de bins actifs

sont ignorees, car leur covariance est trop peu fiable. L'agregation peut etre faite par mediane, par mode ou par quantile eleve afin de rester prudente lorsque certaines frequences ne voient qu'une partie des sources.

Pour le moment, la methode par variance expliquee semble la plus robuste dans nos essais. Elle evite de fixer un seuil directement sur une valeur propre absolue ou relative, et elle se comporte mieux lorsque l'energie des sources est repartie de maniere desequilibree. Cette partie pourrait toutefois etre approfondie : on pourrait imaginer un estimateur plus sophistique.

3.1.5 Masque temps-frequence par default sans reseau de neurones

Lorsque l'on ne dispose pas d'un masque fourni par un reseau de neurones, l'algorithme peut construire un masque temps-frequence par default a partir de l'energie du melange. La STFT multicanale brute est d'abord calculee, puis l'energie d'un bin temps-frequence est definie par :

$$E(f, t) = \sum_{m=1}^M |X_m(f, t)|^2.$$

Cette energie est convertie en decibels :

$$E_{\text{dB}}(f, t) = 10 \log_{10} (E(f, t) + \epsilon).$$

Le seuil d'activation est calcule relativement a un plancher d'energie estime par percentile :

$$\theta = \text{percentile}_p(E_{\text{dB}}) + \Delta_{\text{dB}}.$$

Un bin est conserve si :

$$E_{\text{dB}}(f, t) \geq \theta.$$

Les valeurs utilisees sont typiquement un plancher au percentile 20, un seuil place 6 dB au-dessus de ce plancher, et un minimum de 3 trames actives consecutives par frequence.

Ensuite, un bin actif isole ne fournit pas assez d'information locale pour stabiliser le clustering EM. On filtre donc les activations frequence par frequence en conservant seulement les groupes temporels suffisamment longs. Si $L_{\min}$ designe la longueur minimale, un segment actif n'est conserve que si :

$$\#\{t : (f, t) \text{ actif dans le segment}\} \geq L_{\min}.$$

Ce filtrage est important pour la robustesse de la separation. En pratique, il evite que des fluctuations locales du bruit soient presentees a l'EM comme des observations fiables.

3.2 Algorithme de SAWADA

3.2.1 Clustering EM par frequence

Pour chaque frequence f , l'algorithme extrait les observations actives. Celles-ci sont obtenues soit a partir d'un masque fourni par un reseau de neurones, soit a partir du masque par energie decrit precedemment :

$$\tilde{\mathbf{x}}_{f,t}, \quad t \in \mathcal{T}_f.$$

L'objectif est d'ajuster K clusters, ou K est le nombre de sources. Chaque cluster k est represente par trois parametres :

- un centroïde complexe $\mathbf{a}_{f,k}$;
- une variance $\sigma_{f,k}^2$, qui mesure la dispersion autour de la direction ;
- un poids de melange $\alpha_{f,k}$.

L'initialisation est faite par K-means sur les amplitudes des observations, puis les centroïdes sont normalises sur la sphere unite complexe.

3.2.2 Etape E

L'étape E calcule, pour chaque observation, la probabilité postérieure d'appartenir à chaque cluster. La distance directionnelle utilisée est :

$$d_{k,t}^2 = 1 - \left| \mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t} \right|^2.$$

Cette distance est faible lorsque l'observation est proche de la direction du centroïde, indépendamment d'une phase globale. La probabilité non normalisée associée au cluster k est :

$$q_{k,t} = \alpha_{f,k} \frac{1}{\left(\pi(\sigma_{f,k}^2 + \epsilon) \right)^{M-1}} \exp \left(-\frac{d_{k,t}^2}{\sigma_{f,k}^2 + \epsilon} \right).$$

Les responsabilités EM sont ensuite obtenues par normalisation :

$$\gamma_{k,t} = \frac{q_{k,t}}{\sum_{\ell=1}^K q_{\ell,t} + \epsilon}.$$

3.2.3 Etape M

L'étape M met à jour les paramètres des clusters à partir des responsabilités. Les poids de mélange sont mis à jour avec un prior de Dirichlet ϕ :

$$\alpha_{f,k} = \frac{\sum_t \gamma_{k,t} + \phi}{N_f + K\phi},$$

où N_f est le nombre d'observations actives à la fréquence f .

Le centroïde est estimé comme la direction principale de la matrice de corrélation pondérée :

$$\mathbf{R}_{f,k} = \sum_t \gamma_{k,t} \tilde{\mathbf{x}}_{f,t} \tilde{\mathbf{x}}_{f,t}^H.$$

Le nouveau centroïde $\mathbf{a}_{f,k}$ est le vecteur propre principal de $\mathbf{R}_{f,k}$. La variance est ensuite mise à jour comme la dispersion moyenne pondérée des observations autour de cette direction :

$$\sigma_{f,k}^2 = \frac{\sum_t \gamma_{k,t} \left(1 - \left| \mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t} \right|^2 \right)}{(M-1) \sum_t \gamma_{k,t}}.$$

Les démonstrations détaillées de ces trois mises à jour sont données en annexe A.

En pratique, ces deux étapes sont alternées un nombre fixe de fois. Dans notre cas, vingt itérations donnent déjà un comportement satisfaisant.

3.2.4 Construction des masques de clusters

Après convergence de l'EM, un masque binaire est construit par décision dure. Pour chaque bin actif, on choisit le cluster avec le plus grand score :

$$\hat{k}(f, t) = \arg \max_k \frac{\left| \mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t} \right|^2}{\sigma_{f,k}^2 + \epsilon}.$$

Le masque du cluster k est alors :

$$M_k(f, t) = \begin{cases} 1 & \text{si } \hat{k}(f, t) = k, \\ 0 & \text{sinon.} \end{cases}$$

À ce stade, les masques sont cohérents localement à une fréquence donnée, mais pas encore globalement entre fréquences. Comme l'EM est lancé indépendamment pour chaque fréquence, le cluster numéroté 0 à une fréquence peut correspondre à une autre source que le cluster numéroté 0 à la fréquence suivante. C'est le problème classique de permutation.

3.3 Assignment des clusters à l'une des sources

3.3.1 Motivation

Pour reconstruire une source, il faut que les masques soient cohérents sur toutes les fréquences. Deux stratégies d'alignement sont considérées : une méthode par corrélation d'enveloppes et une méthode par RANSAC circulaire. La validation utilise principalement l'alignement par RANSAC, car il exploite directement la structure physique des phases relatives.

3.3.2 Alignement par corrélation d'enveloppes

L'assignation par corrélation d'enveloppes consiste à associer, pour chaque fréquence, les clusters locaux aux sources globales déjà suivies aux fréquences précédentes. Pour ce faire, on calcule l'enveloppe $e_k^f(t)$ du cluster k à la fréquence f :

$$e_k^f(t) = \sum_m |X_m(f, t)|^2 M_k(f, t)$$

où $M_k(f, t)$ est le masque binaire du cluster k pour la fréquence f .

On calcule ensuite pour chaque combinaison d'attribution possible

$$\pi \in \mathfrak{S}_K$$

un score de cohérence entre les enveloppes du bin courant et les enveloppes de référence déjà associées aux sources. Si $r_s^{f-1}(t)$ désigne l'enveloppe de référence de la source s construite à partir des fréquences précédentes, le score de la permutation π est :

$$C_f(\pi) = \sum_{s=1}^K \rho(e_{\pi(s)}^f(t), r_s^{f-1}(t)),$$

où $\rho(\cdot, \cdot)$ est la corrélation de Pearson :

$$\rho(u, v) = \frac{\sum_t (u(t) - \bar{u})(v(t) - \bar{v})}{\sqrt{\sum_t (u(t) - \bar{u})^2} \sqrt{\sum_t (v(t) - \bar{v})^2} + \epsilon}.$$

La permutation retenue est celle qui maximise cette corrélation totale :

$$\pi_f^* = \arg \max_{\pi \in \mathfrak{S}_K} C_f(\pi).$$

Les masques de la fréquence f sont ensuite reordonnés selon π_f^* :

$$M_s(f, t) \leftarrow M_{\pi_f^*(s)}(f, t).$$

L'enveloppe de référence est finalement mise à jour de façon progressive. Dans une version lissée exponentiellement, cette mise à jour prend la forme :

$$r_s^f(t) = (1 - \beta)r_s^{f-1}(t) + \beta e_{\pi_f^*(s)}^f(t),$$

avec $\beta = 0.1$ dans nos essais. Une fréquence dont l'énergie associée à une source est trop faible ne met pas à jour la référence, afin d'éviter qu'un bin peu informatif dégrade l'alignement des fréquences suivantes.

Cette méthode est simple et ne suppose pas explicitement un modèle de retard. Elle utilise seulement la similarité temporelle des enveloppes : deux clusters appartenant à la même source doivent présenter des activations temporelles corrélées d'une fréquence à l'autre. En revanche, cette méthode dépend de l'ordre de parcours des fréquences, car les basses fréquences servent initialement à construire l'enveloppe de référence. Plusieurs situations, notamment les vocalisations simultanées, peuvent alors donner lieu à des erreurs.

3.3.3 RANSAC circulaire

Conversion des centroïdes en phase relative

Les centroïdes complexes $\mathbf{a}_{f,k}$ contiennent une phase globale arbitraire. Pour la supprimer, on choisit un microphone de reference, note ici 1, et on calcule :

$$z_{f,k,m}^{\text{rel}} = a_{f,k,m} a_{f,k,1}^*.$$

La phase relative associee est :

$$\theta_{f,k,m} = \arg \left(z_{f,k,m}^{\text{rel}} \right).$$

Si le centroïde correspond a une source physique dominee par des retards, alors on attend une relation de la forme :

$$\theta_{f,k,m} \approx b_m - 2\pi f(\tau_m - \tau_1) \pmod{2\pi}.$$

Les phases relatives d'une meme source decrivent donc une droite en frequence, mais observee modulo 2π . Cette propriete est la base du RANSAC circulaire.

Remarque : si les donnees ont ete blanchies en amont, il faut appliquer l'operation inverse aux centroïdes avant le RANSAC. Sinon, les phases traitees ne representent plus directement les droites de retard attendues.

Modele ajusté par RANSAC circulaire

Le modele ajuste est une droite circulaire multidimensionnelle :

$$\boldsymbol{\theta}_i = \mathbf{b} + (f_i - f_{\text{ref}})\mathbf{v} \pmod{2\pi}.$$

La distance d'une observation au modele est calculee apres repliement de phase :

$$d_i = \|\text{wrap}(\boldsymbol{\theta}_i - \mathbf{b} - (f_i - f_{\text{ref}})\mathbf{v})\|_2.$$

Concretement, chaque observation donnee au RANSAC correspond a un centroïde disponible a une frequence donnee. Elle est decrite par sa frequence f_i et par son vecteur de phases relatives :

$$\boldsymbol{\theta}_i = [\theta_{i,1} \quad \cdots \quad \theta_{i,M}]^\top.$$

Le RANSAC construit d'abord des hypotheses de trajectoires a partir de petits echantillons d'observations, typiquement deux centroïdes pris a deux frequences distinctes. Pour une paire (i, j) , la pente candidate doit verifier :

$$\boldsymbol{\theta}_j - \boldsymbol{\theta}_i = (f_j - f_i)\mathbf{v} \pmod{2\pi}.$$

Comme les phases sont definies modulo 2π , plusieurs pentes peuvent expliquer la meme paire d'observations :

$$\mathbf{v} = \frac{\boldsymbol{\theta}_j - \boldsymbol{\theta}_i + 2\pi\mathbf{n}}{f_j - f_i}, \quad \mathbf{n} \in \mathbb{Z}^M.$$

On enumere les hypotheses compatibles avec les bornes physiques sur la pente. Ces bornes proviennent du retard maximal possible entre microphones : comme $v_m = -2\pi\tau_m$, limiter les TDOA revient a limiter les pentes admissibles.

Pour chaque hypothese $(\mathbf{b}, \mathbf{v})$, l'algorithme calcule la distance circulaire de toutes les observations au modele. Une observation est consideree comme un inlier si :

$$d_i < \eta,$$

ou η est le seuil de residu circulaire. Le score utilise est de type MSAC : au lieu de compter seulement les inliers, on somme des residus tronques :

$$S = \sum_i \min(d_i^2, \eta^2).$$

Le meilleur modele est celui qui minimise ce score. Apres selection d'une bonne hypothese, une optimisation locale raffine la pente et l'intercept sur les inliers. Pour une pente fixee, l'intercept optimal est obtenu par moyenne circulaire des phases residuelles :

$$b_m(\mathbf{v}) = \arg \sum_{i \in \mathcal{I}} \exp(j(\theta_{i,m} - (f_i - f_{\text{ref}})v_m)),$$

ou $\mathcal{I}$ designe l'ensemble des inliers.

Comme il y a plusieurs sources, l'extraction est sequentielle. Le RANSAC trouve d'abord la trajectoire la plus coherente, associe les centroïdes compatibles a cette source, puis retire ou marque ces centroïdes avant de chercher la trajectoire suivante. Cette procedure est repetee jusqu'a obtenir K trajectoires, c'est-a-dire une trajectoire de phase par source attendue.

Enfin, tous les centroïdes disponibles sont assignes a la trajectoire la plus proche. Les centroïdes trop eloignes de toutes les trajectoires peuvent etre marques comme non assignes. Les labels obtenus permettent ensuite de fusionner les masques de clusters en masques de sources coherents sur l'ensemble des frequences.

Lien entre pente de phase et TDOA

La pente estimee pour le microphone m a une interpretation directe :

$$v_m = -2\pi(\tau_m - \tau_{\text{ref}}).$$

Le retard relatif au microphone de reference est donc :

$$\tau_m - \tau_{\text{ref}} = -\frac{v_m}{2\pi}.$$

Les TDOA entre paires de microphones sont ensuite calcules par difference :

$$\Delta\tau_{i,j} = \tau_j - \tau_i.$$

En revanche, les TDOA estimes a partir de la pente recuperee par le RANSAC sont souvent moins fiables que ceux obtenus par les autres methodes. Cette information reste utile pour ameliorer la coherence des masques, mais elle n'est pas utilisee directement pour calculer les TDOA finaux. La figure 1 illustre l'attribution des centroïdes et la droite trouvee par le RANSAC.

Merge automatique de clusters

Dans le cas ou une frequence ne contient pas toutes les sources, la methode par correlation peut separer artificiellement les bins de cette frequence. La methode RANSAC permet au contraire d'attribuer plusieurs clusters d'une meme frequence a la meme source. Comme le montre la figure 2, deux clusters proches peuvent finalement etre attribues a une seule et meme source.






FIGURE 1 – Argument de la composante i en fonction de la fréquence du centroïde.



Attribution des bins par cluster.



Attribution après le RANSAC.

FIGURE 2 – Merge automatique de clusters : comparaison entre l'attribution initiale des clusters et l'attribution après RANSAC.

3.4 Fusion finale des masques

Une fois les centroïdes associes a des sources, les masques de clusters sont fusionnes. Pour une source s , le masque final est :

$$M_s(f, t) = \sum_{k: \text{label}(f, k)=s} M_k(f, t).$$

Une fois les masques de sources obtenus, on reconstruit d'abord, pour chaque source s , une STFT multicanale masquee. Si $\mathbf{X}(f, t)$ designe la STFT du melange original et $M_s(f, t)$ le masque associe a la source s , on calcule :

$$\hat{\mathbf{X}}_s(f, t) = M_s(f, t) \mathbf{X}(f, t).$$

Le meme masque est applique a tous les microphones. On conserve ainsi les bins temps-frequence attribues a la source s , tout en gardant les differences de phase entre microphones presentes dans la STFT originale.

On applique ensuite une STFT inverse a chaque canal de $\hat{\mathbf{X}}_s(f, t)$ afin d'obtenir une reconstruction temporelle multicanale :

$$\hat{\mathbf{x}}_s[n] = \text{iSTFT} \left(\hat{\mathbf{X}}_s(f, t) \right).$$

Les TDOA peuvent alors etre estimes sur ces signaux temporels reconstruits. Cette methode n'a pas de garantie theorique forte. En effet, une STFT masquee bin par bin ne correspond pas necessairement a la STFT exacte d'un signal physique reel : le masquage peut introduire des incoherences entre trames et entre frequences. La reconstruction par iSTFT doit donc etre vue comme un signal ayant une STFT proche de la STFT masquee du signal original, et non comme une reconstruction parfaite de la source originale.

Malgre cette limite, l'approche fonctionne relativement bien en pratique sur le benchmark. Elle fournit une premiere estimation simple des TDOA, directement exploitable apres la separation. Sa qualite depend principalement de la qualite du masque final : une erreur de separation ou d'assignation de clusters peut deteriorer les signaux reconstruits, et donc les retards estimes par correlation.

4 Calcul des TDOA a partir des bins isoles

4.1 Beamforming masque

Cette partie est traitee separement.

5 Validation sur un dataset synthetique

5.1 Validation de la separation de sources

5.1.1 Creation des signaux synthetiques

La validation de la separation repose sur des scenes synthetiques pour lesquelles on connait les sources originales et les retards appliques sur chaque microphone. Une scene est construite en generant d'abord plusieurs signaux monophoniques representant les sources acoustiques d'interet, puis en les plaçant dans le temps avec un gain et une fenetre d'apparition. Ces sources sont ensuite propagees vers les microphones par un modele de melange a retards.

Pour modeliser les vocalisations de belugas, on utilise un signal de type sifflement harmonique a frequence instantanee variable. On definit d'abord un contour frequenciel fondamental $f_0(t)$, obtenu a partir de quelques points de controle relies par une interpolation lisse. Ce contour peut

monter ou descendre au cours du temps, avec des changements de direction aleatoires, puis un faible jitter temporellement correle est ajoute :

$$f_{\text{inst}}(t) = \text{clip}(f_0(t) + \eta(t), f_{\min}, f_{\max}).$$

La phase instantanee du sifflement est obtenue par integration de cette frequence :

$$\varphi(t) = 2\pi \int_0^t f_{\text{inst}}(u) du.$$

En temps discret, cette integration s'ecrit sous forme cumulative :

$$\varphi[n] = \frac{2\pi}{f_s} \sum_{\ell=0}^n f_{\text{inst}}[\ell].$$

Le signal de beluga est ensuite construit comme une somme d'harmoniques de cette phase :

$$s[n] = A[n] \sum_{h=1}^H a_h \sin(h\varphi[n] + \psi_h),$$

ou a_h est l'amplitude de l'harmonique h , ψ_h sa phase initiale et $A[n]$ une enveloppe lente. Les amplitudes harmoniques decroissent globalement avec l'ordre harmonique, avec une petite variation aleatoire, ce qui produit des sifflements spectraux plausibles sans rendre toutes les realisations identiques.

Le melange multicanal est ensuite obtenu en appliquant un retard entier $d_{m,k}$ entre la source k et le microphone m :

$$x_m[n] = \sum_{k=1}^K g_{m,k} s_k[n - d_{m,k}] + b_m[n],$$

ou $g_{m,k}$ represente un gain eventuel et $b_m[n]$ regroupe les bruits ajoutes au microphone m , qui peuvent etre gaussiens ou impulsifs. Les retards $d_{m,k}$ etant connus, les TDOA de reference sont directement disponibles :

$$\Delta\tau_{i,j,k}^{\text{ref}} = \frac{d_{j,k} - d_{i,k}}{f_s}.$$

Ce cadre synthetique permet donc de tester la separation dans une situation ou l'on connait a la fois les sources propres, le melange observe et la solution spatiale attendue. La forme des signaux choisis permet d'obtenir des signaux proches de sifflements, avec une frequence variable et une certaine continuite frequentielle.

5.1.2 Evaluation de la separation

Resultats qualitatifs

La figure 3 illustre d'abord les resultats de separation dans le plan temps-frequence. Elle permet de verifier visuellement que les bins actifs sont bien repartis entre les sources estimees et que les masques obtenus suivent les structures spectrales principales du melange. D'un point de vue qualitatif, la separation est relativement bonne. On ajoute ensuite du bruit au melange, avec un SNR qui varie entre 0 et 10 dB. La figure 4 illustre les resultats obtenus. La figure 5 quant à elle montre l'attribution des centroïdes dans le cas bruité. Contrairement au cas sans bruit, les droites de phase sont tres difficiles a percevoir a l'oeil nu : le bruit rend les trajectoires moins nettes et les points semblent beaucoup moins organises. L'algorithme RANSAC parvient toutefois a separer systematiquement les clusters appartenant a la bonne source, ce qui n'etait pas evident visuellement.




FIGURE 3 – Resultats de separation de sources dans le plan temps-frequence. A gauche, les sources 1 et 2; au milieu, le melange; a droite, les sources estimees 1 et 2.






FIGURE 4 – Resultats de separation de sources dans le plan temps-frequence avec bruit. A gauche, les sources 1 et 2 ; au milieu, le melange ; a droite, les sources estimees 1 et 2.



Centroides en presence de bruit.



Droite obtenue apres l'attribution par RANSAC.

FIGURE 5 – L'attribution est correcte, alors qu'elle est loin d'être évidente a la main. Cela fonctionne notamment parce que la preselection des bins limite le nombre de bins ne representant pas de signal utile.

Resultats quantitatifs

La figure 6 donne ensuite une analyse plus quantitative, en comparant les TDOA obtenus a partir des sources reconstruites (c'est-a-dire une methode simple qui n'est pas supposee donner des resultats parfaits, comme discute dans la partie 3.4). Cette visualisation permet d'évaluer si la separation conserve suffisamment la coherence temporelle entre microphones pour fournir une premiere estimation fiable des retards. De meme, la figure 7 presente les TDOA obtenus dans la situation bruitée.

On notera que les TDOA obtenus lors des essais en conditions reelles de mai 2026 presentent des variances et des ecart a la ground truth d'environ 3 a 4 echantillons. Les resultats obtenus ici sont donc tout a fait satisfaisants.




FIGURE 6 – Analyse quantitative des TDOA estimates par correlation sur les sources separees.




FIGURE 7 – Analyse quantitative des TDOA estimates par correlation sur les sources separees en présence de bruit.

5.1.3 Source d’erreurs

Comme nous l’avons vu, les resultats ne sont pas parfaits. Il existe plusieurs sources d’erreurs que l’on essaie d’explorer ici.

Mauvaise estimation des bins contenant du signal en presence de bruit

On utilise ici la methode decrite dans la partie 3.1.5. Elle fonctionne bien sans bruit et avec un bruit modere, mais on constate tout de meme que plusieurs zones sont considerees comme actives alors qu’elles ne devraient pas l’etre. La selection de bins peut sans doute etre amelieree, comme on peut le voir sur la figure 8. Cela motive l’utilisation d’un reseau de neurones pour cette tache, qui s’apprend bien mais reste loin d’etre triviale. Une autre possibilite consiste a ajuster les hyperparametres, notamment le nombre de bins adjacents necessaire pour considerer une zone comme valide.




FIGURE 8 – Comparaison de l’estimation des bins contenant du signal par seuillage d’energie, sans bruit et avec bruit.

Mauvaise droite dans le RANSAC

Dans le cas sans bruit, l’extrait numero 14 ne fonctionne pas correctement (figure 9). En regardant plus en detail, on remarque que certains bins contenant du signal ne sont attribues a aucune des deux sources. C’est le cas, par exemple, des bins centraux de la frequence 2250 Hz. Au niveau du clustering (figure 10), la separation locale semble pourtant correcte : les points situes aux

extremities sont bien distinguées des points centraux. Le problème apparaît ensuite au niveau du RANSAC (figure 11). En comparaison avec les droites de ground truth, les deux droites trouvées par RANSAC correspondent en réalité à la même source. La seconde droite est donc totalement ignorée. Ce cas reste rare, avec ou sans bruit, mais peut tout de même se produire. Augmenter le nombre d'itérations du RANSAC peut améliorer cette situation. A priori, ce problème est dû à une mauvaise sélection des bins ou à un recouvrement trop important entre les deux sources.




FIGURE 9 – Extrait 14 : melange et sources de reference.





FIGURE 10 – Extrait 14 : clusters de bins temps-frequence dans $\mathbb{C}^4$ pour $f = 2250$ Hz, avant et apres attribution a une source. Un cluster pourtant propre n'a pas ete conserve apres le RANSAC.


5.2 Validation du beamforming

La seconde validation concerne l'utilisation des bins isolés pour le beamforming. L'objectif n'est plus seulement de reconstruire les sources, mais d'utiliser les masques temps-frequence pour guider une methode d'estimation spatiale. Les bins selectionnes par le masque peuvent etre utilises comme poids ou comme zones d'interet dans le calcul du pseudo-spectre.

On compare alors les directions ou TDOA obtenus par beamforming masque aux valeurs de reference disponibles dans le dataset. Cette validation permet d'évaluer si la separation temps-frequence améliore effectivement l'estimation spatiale, en reduisant l'influence des bins domines par le bruit ou par les autres sources.



Attribution de reference.



Droite estimee par RANSAC.

FIGURE 11 – Extrait 14 : comparaison entre la reference et la droite estimee par RANSAC. Une des droites est bien identifiee, mais la seconde n'est pas obtenue correctement.

6 Analyse des donnees 2026

6.1 Introduction

On etudie a present les resultats obtenus sur les donnees de 2026. Ces donnees ne permettent pas vraiment de tester la separation de sources, mais elles permettent, lorsqu'une source de localisation connue est disponible, de verifier si le pipeline de detection retrouve une position coherente. Les points analyses vont de 7 a 20, selon le plan presente figure 12. Chaque point est caracterise par deux enregistrements de 100 secondes, un pour chaque tetraedre, synchronises manuellement. La difference de temps d'arrivee entre les deux tetraedres n'est donc pas traitee ici.





FIGURE 12 – Plan des données 2026.

Premiers resultats


La qualité de l'estimation dépend fortement de la position du bateau. Parmi les positions testées, les résultats sont satisfaisants pour les points 7, 9, 10, 11, 12 et 13. L'estimation du point 8 est fortement dégradée par le bruit d'un second bateau, tandis que les points du début d'après-midi, de 14 à 20, présentent un biais apparent. Le meilleur résultat est obtenu pour le point 7 ; le point 11 est le cas le plus difficile parmi ceux pour lesquels l'algorithme reste exploitable. La figure 14 donne un aperçu des directions estimées. Il faut toutefois éviter d'interpréter toute la dispersion des directions comme de la variance algorithmique. Sur le point 7, par exemple, le bateau dérive et la ground truth se déplace également. La figure 15, où les directions sont colorées en fonction du temps, permet de mieux distinguer cette dérive de la variance propre à l'algorithme. Enfin, certaines directions semblent totalement erronées : le début et la fin de chaque extrait audio ne contiennent pas nécessairement le signal d'intérêt. Ces instants ont tout de même été conservés sur les figures afin de visualiser d'éventuelles sources de bruit utiles pour l'interprétation.

POINT	POSITIONS	DIST. MED. GT
7	87	41.2 m
8	74	1004.9 m
9	79	251.5 m
10	79	280.6 m
11	85	550.3 m
12	80	239.5 m
13	89	104.6 m
14	87	88.6 m
15	94	283.8 m
16	90	629.7 m
17	92	1063.2 m
18	95	474.6 m
19	95	200.5 m
20	88	487.6 m


FIGURE 13 – Synthèse des premiers résultats avec la high fusion 2D : distance médiane à la ground truth.




Direction estimee pour p7.




Direction estimee pour p9.




Direction estimee pour p10.




Direction estimee pour p11.



Direction estimee pour p12.



Direction estimee pour p13.



Evolution temporelle de la direction pour p7.

Evolution temporelle de la direction pour p11.

FIGURE 15 – Evolution temporelle des directions estimees pour les points p7 et p11.

6.2 Comparaison des differentes methodes d'estimation de position

Trois methodes permettent d'estimer la position des belugas a partir des TDOA mesures : la high fusion 3D, la high fusion 2D, c'est-a-dire avec projection sur le plan du sol, et la low fusion. Les figures 17 et 16 presentent les resultats obtenus et permettent de mieux comprendre les differences entre ces approches.

Tout d'abord, les modes high fusion 3D et low fusion donnent des resultats relativement proches sur l'ensemble des positions testees. La high fusion presente toutefois un leger avantage, en plus de fournir une meilleure interpretabilite des directions estimees par chaque tetraedre.

Concernant la comparaison entre les estimations 3D et 2D, la projection 2D donne en moyenne de meilleures estimations de position. Cela s'explique par le fait que la source et les deux tetraedres sont approximativement a la meme hauteur. En realite, il serait probablement preferable de projeter dans le plan defini par la source et les deux tetraedres. En revanche, l'utilisation de h_4 reste necessaire. Les directions estimees a partir des TDOA obtenus avec et sans h_4 montrent que les resultats se degradent fortement sans ce microphone supplementaire. Celui-ci apporte trois TDOA supplementaires, comme le montre la figure 18.




FIGURE 16 – Comparaison des differentes methodes pour la position p13.




FIGURE 17 – Comparaison des differentes methodes pour la position p12.




FIGURE 18 – Comparaison des directions estimees pour la position p13 avec et sans h_4 .

6.3 Point ne fonctionnant pas bien

6.3.1 Point numero 8 : bateau






FIGURE 19 – Directions estimees pour le point 8 en high fusion 2D.



Spectrogramme du point 7.



Spectrogramme du point 8.

FIGURE 20 – Comparaison des spectrogrammes des points 7 et 8.

6.3.2 Point 14 à 20 : biais apparent

Pour les points 14 a 20 presentes ci-dessous, les directions estimees presentent un biais, mais pas davantage de variance que d'habitude. Nous n'avons aucune certitude quant a la cause de ces resultats.

Une premiere hypothese serait qu'une seconde source domine le signal du bateau. Cependant, le point 8 montre qu'une source parasite forte conduit plutot a une forte variance. De plus, l'analyse des instants sans signal d'interet n'a pas permis d'identifier une direction parasite unique. L'hypothese d'un bruit proche des microphones qui biaiserait les resultats semble donc peu probable.

Une seconde hypothese serait une rotation des microphones pendant l'experimentation. Environ deux heures se sont ecoulees entre la mesure du point 7 et celle du point 20. Les tetraedres pesent plusieurs tonnes, mais ils sont poses sur du sable, qui peut potentiellement bouger. Toutefois, les resultats ne semblent pas compatibles avec une rotation constante unique.

Enfin, une derniere hypothese serait une desynchronisation de certains microphones. La figure 25 montre l'impact de la desynchronisation du microphone situe au sud-est du tetraedre sur la direction estimee. Certaines directions sont alors correctement predites, tandis que d'autres sont decalees, avec une erreur qui augmente notamment lorsque l'on s'eloigne de l'axe nord-ouest/sud-est. Toutefois, les points 18 et 19 constituent un contre-exemple : les directions attendues sont quasiment les memes, alors que les biais observes sont differents.

Ainsi, nous n'avons pas de reponse claire sur l'origine exacte du probleme. Cependant, la faible variance des directions estimees reste encourageante : l'algorithme ne produit pas un resultat aleatoire, mais semble affecte par un element biaisant dont la source n'a pas encore ete identifiee.






FIGURE 21 – Directions estimees en high fusion 2D pour les points 14 et 15.




Direction estimee pour p16.




Direction estimee pour p17.

FIGURE 22 – Directions estimees en high fusion 2D pour les points 16 et 17.




Direction estimee pour p18.



Direction estimee pour p19.

FIGURE 23 – Directions estimees en high fusion 2D pour les points 18 et 19.



Direction estimee pour p20.

FIGURE 24 – Direction estimee en high fusion 2D pour le point 20.




FIGURE 25 – Simulation des retards microphones.

7 Conclusion

L'algorithme de separation etudie exploite la structure physique des signaux multicanaux dans le domaine temps-frequence. Sous l'hypothese qu'un bin actif est localement domine par une source, l'observation multicanale peut etre modelisee comme un coefficient complexe multiplie par un vecteur spatial de retards. Cette structure permet de transformer le probleme de separation en un probleme de clustering de directions complexes.

Le clustering EM estime, pour chaque frequence, des centroïdes correspondant aux signatures spatiales locales des sources. Le RANSAC circulaire resout ensuite le probleme de permutation entre frequences en cherchant des trajectoires de phase compatibles avec des retards physiques. Les masques finaux permettent de reconstruire les sources et de calculer des TDOA, soit par cor-

relation sur les signaux reconstruits, soit a partir des pentes de phase, soit encore en alimentant un beamformer masque.

La validation sur un dataset synthétique fournit un cadre reproductible pour mesurer les erreurs de TDOA et inspecter les artefacts internes de l'algorithme. Les prochaines étapes naturelles consistent à compléter les résultats quantitatifs, étudier la sensibilité aux niveaux de bruit et comparer systématiquement l'apport du masque temps-fréquence dans la qualité finale de la séparation et des TDOA. Aussi, une comparaison des TDOA obtenus VS TDOA attendu a montré que si désynchronisation il y a eu, celle-ci a eu lieu plusieurs fois et sur plusieurs microphone car aucune paire de microphone ne donnait une TDOA valide sur l'ensemble des points et aucune paire de tdoa ne donnait une erreur constante sur l'ensemble des points.

A Demonstrations des mises à jour EM

Dans l'algorithme de Sawada, l'étape M consiste à maximiser l'espérance de la log-vraisemblance complète par rapport aux paramètres de chaque source. Pour une fréquence donnée, on note $\mathcal{X} = \{\tilde{\mathbf{x}}_t\}_{t=1}^T$ l'ensemble des observations normalisées, avec $\|\tilde{\mathbf{x}}_t\|_2 = 1$. Pour une source i , les paramètres sont le centroïde $\mathbf{a}_i$, contraint par $\|\mathbf{a}_i\|_2 = 1$, la variance σ_i^2 et le poids de mélange α_i .

La quantité maximisée par l'EM est :

$$Q = \sum_{t=1}^T \sum_{i=1}^K \gamma_{i,t} \left[\ln(\alpha_i) + \ln p(\tilde{\mathbf{x}}_t | \mathbf{a}_i, \sigma_i^2) \right].$$

A.1 Mise à jour des poids

Sans régularisation, la mise à jour des poids maximise :

$$\sum_{i=1}^K \sum_{t=1}^T \gamma_{i,t} \ln(\alpha_i) \quad \text{sous la contrainte} \quad \sum_{i=1}^K \alpha_i = 1.$$

En utilisant un multiplicateur de Lagrange λ , on dérive :

$$\frac{\partial}{\partial \alpha_i} \left(\sum_{i,t} \gamma_{i,t} \ln(\alpha_i) - \lambda \sum_i \alpha_i \right) = \frac{\sum_t \gamma_{i,t}}{\alpha_i} - \lambda = 0.$$

On obtient donc :

$$\alpha_i = \frac{\sum_t \gamma_{i,t}}{\lambda}.$$

Puisque $\sum_i \alpha_i = 1$, on a :

$$\lambda = \sum_i \sum_t \gamma_{i,t} = T.$$

D'où :

$$\alpha_i = \frac{\sum_t \gamma_{i,t}}{T}.$$

L'ajout de ϕ correspond à l'introduction d'un prior de Dirichlet pour régulariser l'estimation. Dans ce cas, la mise à jour devient :

$$\alpha_i = \frac{\sum_t \gamma_{i,t} + \phi}{T + K\phi}.$$

A.2 Mise a jour du centroïde

Le terme de la log-vraisemblance dependant du centroïde $\mathbf{a}_i$ est :

$$Q(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \left(-\frac{\left\| \tilde{\mathbf{x}}_t - \left(\mathbf{a}_i^H \tilde{\mathbf{x}}_t \right) \mathbf{a}_i \right\|_2^2}{\sigma_i^2} \right).$$

Puisque $\|\tilde{\mathbf{x}}_t\|_2 = 1$ et $\|\mathbf{a}_i\|_2 = 1$, la distance a la projection verifie :

$$\left\| \tilde{\mathbf{x}}_t - \left(\mathbf{a}_i^H \tilde{\mathbf{x}}_t \right) \mathbf{a}_i \right\|_2^2 = 1 - \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2.$$

Maximiser $Q(\mathbf{a}_i)$ revient donc a maximiser :

$$\mathcal{J}(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2.$$

Cette quantite peut s'ecrire sous forme quadratique :

$$\mathcal{J}(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \mathbf{a}_i^H \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H \mathbf{a}_i = \mathbf{a}_i^H \left(\sum_{t=1}^T \gamma_{i,t} \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H \right) \mathbf{a}_i.$$

En posant :

$$\mathbf{R}_i = \sum_{t=1}^T \gamma_{i,t} \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H,$$

on cherche :

$$\max_{\mathbf{a}_i} \mathbf{a}_i^H \mathbf{R}_i \mathbf{a}_i \quad \text{sous la contrainte} \quad \mathbf{a}_i^H \mathbf{a}_i = 1.$$

Par la methode des multiplicateurs de Lagrange, on maximise :

$$\mathcal{L} = \mathbf{a}_i^H \mathbf{R}_i \mathbf{a}_i - \lambda \left(\mathbf{a}_i^H \mathbf{a}_i - 1 \right).$$

La condition d'optimalite donne :

$$\mathbf{R}_i \mathbf{a}_i = \lambda \mathbf{a}_i.$$

Le maximum est donc atteint pour le vecteur propre associe a la plus grande valeur propre de $\mathbf{R}_i$. Cette mise a jour revient donc a effectuer une decomposition en valeurs propres de la matrice de correlation ponderee.

A.3 Mise a jour de la variance

La densite de probabilite sur l'hypersphere complexe de dimension M est proportionnelle a :

$$p\left(\tilde{\mathbf{x}}_t \mid \mathbf{a}_i, \sigma_i^2\right) = \frac{1}{(\pi \sigma_i^2)^{M-1}} \exp \left(-\frac{1 - \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2}{\sigma_i^2} \right).$$

En posant :

$$d_{i,t}^2 = 1 - \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2,$$

le terme de Q dependant de σ_i^2 s'ecrit :

$$Q(\sigma_i^2) = \sum_{t=1}^T \gamma_{i,t} \left[-(M-1) \ln(\sigma_i^2) - \frac{d_{i,t}^2}{\sigma_i^2} \right].$$

On derive ensuite par rapport a σ_i^2 :

$$\frac{\partial Q}{\partial \sigma_i^2} = -\frac{(M-1) \sum_t \gamma_{i,t}}{\sigma_i^2} + \frac{\sum_t \gamma_{i,t} d_{i,t}^2}{(\sigma_i^2)^2}.$$

En annulant cette derivee, on obtient :

$$(M-1) \sigma_i^2 \sum_t \gamma_{i,t} = \sum_t \gamma_{i,t} d_{i,t}^2.$$

D'ou :

$$\sigma_i^2 = \frac{\sum_t \gamma_{i,t} d_{i,t}^2}{(M-1) \sum_t \gamma_{i,t}}.$$