

Rapport sur un algorithme de separation de sources acoustiques

A completer

18 août 2026

Résumé

Ce rapport decrit un pipeline de traitement audio multicanal destine a isoler plusieurs sources acoustiques puis a estimer leurs differences de temps d'arrivee entre microphones. Le pipeline s'appuie d'abord sur une selection de bins dans le plan temps-frequence, afin de ne conserver que les zones contenant du signal exploitable. La partie principale du rapport porte ensuite sur l'algorithme de separation de sources implemente dans le module **BSS**. Cette methode modelise chaque bin actif comme un coefficient complexe de source multiplie par un vecteur spatial de retards, applique un clustering EM independant par frequence, puis resout le probleme de permutation entre frequences par un RANSAC circulaire sur les phases relatives des centroïdes. Enfin, les sources separees ou les bins isolés peuvent etre utilises pour estimer les TDOA, notamment via des methodes de beamforming masquées ou ponderees.

Table des matières

1	Introduction	3
2	Creation d'un masque temps-frequence	3
2.1	Representation temps-frequence multicanale	3
2.2	Selection des bins actifs par energie	3
2.3	Utilisation d'un reseau de neurones	4
3	Separation de sources dans le masque temps-frequence	4
3.1	Préliminaires	4
3.1.1	Hypothese de parcimonie locale	4
3.1.2	Justification de la forme des bins	4
3.1.3	Normalisation et blanchiment des observations	5
3.2	Algorithme de SAWADA	6
3.2.1	Clustering EM par frequence	6
3.2.2	Etape E	6
3.2.3	Etape M	6
3.2.4	Construction des masques de clusters	7
3.3	Assignment des clusters à l'une des sources	7
3.3.1	Motivation	7
3.3.2	Alignement par correlation d'enveloppes	7
3.3.3	RANSAC circulaire	8
3.4	Fusion finale des masques	10
4	Calcul des TDOA a partir des bins isolés	10
4.1	TDOA sur sources separees	10
4.2	Beamforming masque	10
5	Validation sur un dataset synthétique	10

6	Conclusion	10
A	Demonstrations des mises a jour EM	11
A.1	Mise a jour des poids	11
A.2	Mise a jour du centroïde	11
A.3	Mise a jour de la variance	12

1 Introduction

L'estimation de la position ou de la direction d'une source acoustique dans un milieu naturel repose souvent sur l'exploitation d'un reseau de microphones. Si une source emit un signal, celui-ci est observe par chaque microphone avec un retard et une attenuation qui dependent de la geometrie de propagation. Les differences de temps d'arrivee, ou TDOA pour *Time Difference Of Arrival*, contiennent donc une information spatiale directement liee a la source.

Dans un contexte realiste, plusieurs sources peuvent etre actives simultanement, et le signal observe est un melange de contributions utiles et de bruits. Le probleme consiste alors a isoler les composantes associees a chaque source avant d'estimer leurs retards respectifs. Le pipeline considere dans ce rapport est organise en trois etapes principales :

1. construire un masque temps-frequence afin de selectionner les bins ou du signal est present ;
2. separer les sources a l'interieur de ces bins actifs ;
3. calculer les TDOA a partir des bins isolees, en particulier par beamforming.

La contribution principale de ce rapport concerne la deuxieme etape. Elle correspond au module de separation de sources present dans BSS, et plus precisement a l'algorithme de type Sawada/LOST implemente dans `BSS/Algo_Separation/Sawada_separation.py`. Cette methode exploite la structure spatiale des coefficients de STFT multicanaux : dans une zone temps-frequence locale, un bin actif est souvent domine par une seule source. Les observations associees a une meme source forment alors des directions complexes coherentes dans l'espace des microphones.

2 Creation d'un masque temps-frequence

2.1 Representation temps-frequence multicanale

On note $x_m[n]$ le signal temporel observe par le microphone m , avec $m \in \{1, \dots, M\}$. Pour chaque microphone, une transformee de Fourier a court terme est calculee :

$$X_m(f, t) = \text{STFT}\{x_m[n]\}(f, t),$$

ou f designe l'indice de frequence et t l'indice de trame temporelle.

Les observations multicanales sont ensuite regroupees sous forme vectorielle :

$$\mathbf{x}_{f,t} = \begin{bmatrix} X_1(f, t) & X_2(f, t) & \dots & X_M(f, t) \end{bmatrix}^\top \in \mathbb{C}^M.$$

Cette representation est centrale pour le pipeline. L'amplitude des coefficients permet d'identifier les zones temps-frequence contenant de l'energie utile. La phase relative entre les microphones permet quant a elle d'exploiter la geometrie de propagation et donc de distinguer les sources.

Le masque temps-frequence a pour objectif de selectionner les bins (f, t) qui contiennent du signal utile. Cette etape reduit le nombre d'observations traitees par l'algorithme de separation et limite l'influence des bins domines par le bruit.

2.2 Selection des bins actifs par energie

la STFT multicanale brute est d'abord calculee. L'energie d'un bin temps-frequence est ensuite definie par :

$$E(f, t) = \sum_{m=1}^M |X_m(f, t)|^2.$$

Cette energie est convertie en decibels :

$$E_{\text{dB}}(f, t) = 10 \log_{10} (E(f, t) + \epsilon).$$

Le seuil d'activation est calcule relativement a un plancher d'energie estime par percentile :

$$\theta = \text{percentile}_p(E_{\text{dB}}) + \Delta_{\text{dB}}.$$

Un bin est conserve si :

$$E_{\text{dB}}(f, t) \geq \theta.$$

Dans la configuration de benchmark presente dans `BSS/Benchmark/runners.py`, les valeurs utilisees sont typiquement un plancher au percentile 20, un seuil place 6 dB au-dessus de ce plancher, et un minimum de 3 trames actives consecutives par frequence.

Ensuite, un bin actif isole ne fournit pas assez d'information locale pour stabiliser le clustering EM. L'implementation filtre donc les activations frequence par frequence en conservant seulement les groupes temporels suffisamment longs. Si $L_{\min}$ designe la longueur minimale, un segment actif n'est conserve que si :

$$\#\{t : (f, t) \text{ actif dans le segment}\} \geq L_{\min}.$$

Ce filtrage est important pour la robustesse de la separation. En pratique, il evite que des fluctuations locales du bruit soient presentees a l'EM comme des observations fiables.

On pourrait également penser à utiliser des filtres plus developés voir meme des CNN. Cela nous mène à la seconde approche.

2.3 Utilisation d'un réseau de neurones

3 Separation de sources dans le masque temps-frequence

3.1 Préliminaires

3.1.1 Hypothese de parcimonie locale

L'algorithme de separation repose sur une hypothese de parcimonie temps-frequence. Dans une zone locale du plan temps-frequence, un bin actif est souvent domine par une seule source. Pour une source k , on peut alors ecrire :

$$\mathbf{x}_{f,t} \simeq s_k(f, t) \mathbf{a}_k(f),$$

ou $s_k(f, t) \in \mathbb{C}$ est le coefficient complexe de la source et $\mathbf{a}_k(f) \in \mathbb{C}^M$ est le vecteur spatial associe a cette source.

Le probleme de separation devient donc un probleme de regroupement de directions complexes. A frequence fixee, les bins domines par la meme source doivent se regrouper autour d'un meme vecteur spatial.

3.1.2 Justification de la forme des bins

On suppose que la propagation d'une source k vers un microphone m peut etre approximativement decrite par un gain $\rho_{m,k}$ et un retard $\tau_{m,k}$. Dans le domaine frequentiel, un retard temporel se traduit par une phase lineaire en frequence :

$$X_m(f, t) \simeq \rho_{m,k} e^{-j2\pi f \tau_{m,k}} S_k(f, t).$$

En empilant les observations de tous les microphones, on obtient :

$$\mathbf{x}_{f,t} \simeq S_k(f, t) \begin{bmatrix} \rho_{1,k} e^{-j2\pi f \tau_{1,k}} \\ \rho_{2,k} e^{-j2\pi f \tau_{2,k}} \\ \vdots \\ \rho_{M,k} e^{-j2\pi f \tau_{M,k}} \end{bmatrix} = S_k(f, t) \mathbf{a}_k(f).$$

Cette equation justifie la forme utilisee par l'algorithme : un bin est modelise comme un coefficient complexe scalaire, propre au contenu de la source, multiplie par un vecteur complexe qui encode la signature spatiale. Cette signature contient en particulier les retards relatifs entre microphones. De plus, comme les micros sont proches, on peut negliger les differences d'amplitude entre les microphones. (et surtout ne pas s'appuyer dessus pour l'algorithme)

3.1.3 Normalisation et blanchiment des observations

L'algorithme cherche principalement a separer les directions spatiales, et non les amplitudes. Les bins sont donc normalises individuellement :

$$\tilde{\mathbf{x}}_{f,t} = \frac{\mathbf{x}_{f,t}}{\|\mathbf{x}_{f,t}\|_2 + \epsilon}.$$

Apres normalisation, on obtient approximativement :

$$\tilde{\mathbf{x}}_{f,t} \approx e^{j\phi_{f,t}} \frac{\mathbf{a}_k(f)}{\|\mathbf{a}_k(f)\|_2}.$$

Le facteur $e^{j\phi_{f,t}}$ correspond a une phase globale. Il ne porte pas l'information spatiale utile, qui est contenue dans les phases relatives entre microphones. C'est pourquoi l'algorithme travaille sur des distances directionnelles invariantes a cette phase globale.

Dans l'implementation, il est aussi possible d'ajouter une etape de blanchiment spatial apres cette premiere normalisation. Pour chaque frequence f , on considere la matrice des observations normalisees :

$$\tilde{\mathbf{X}}_f = \begin{bmatrix} \tilde{\mathbf{x}}_{f,1} & \tilde{\mathbf{x}}_{f,2} & \cdots & \tilde{\mathbf{x}}_{f,T} \end{bmatrix}.$$

On estime alors la matrice de correlation spatiale :

$$\mathbf{C}_f = \frac{1}{T} \tilde{\mathbf{X}}_f \tilde{\mathbf{X}}_f^H.$$

Cette matrice est diagonalisee :

$$\mathbf{C}_f = \mathbf{U}_f \mathbf{\Lambda}_f \mathbf{U}_f^H,$$

ou $\mathbf{\Lambda}_f$ contient les valeurs propres et $\mathbf{U}_f$ les vecteurs propres. La matrice de blanchiment appliquee dans le code est :

$$\mathbf{W}_f = \mathbf{\Lambda}_f^{-1/2} \mathbf{U}_f^H.$$

Les observations blanchies sont donc :

$$\mathbf{y}_{f,t} = \mathbf{W}_f \tilde{\mathbf{x}}_{f,t}.$$

Apres blanchiment, les directions sont transformees dans un espace ou la correlation spatiale globale est normalisee :

$$\frac{1}{T} \sum_t \mathbf{y}_{f,t} \mathbf{y}_{f,t}^H \approx \mathbf{I}.$$

Cette operation reduit les correlations communes entre microphones et peut rendre les directions des sources plus faciles a separer par l'EM. En revanche, les centroïdes estimes ne vivent plus directement dans l'espace physique original des microphones : ils sont exprimes dans l'espace blanchi. Lorsque l'on veut interpreter leurs phases comme des retards, il faut donc appliquer l'inverse du blanchiment aux centroïdes avant l'assignation spatiale ou l'analyse des TDOA. C'est ce que fait la propriete `all_centroids_unwhitened` : si le blanchiment est active, elle applique la pseudo-inverse de $\mathbf{W}_f$ aux centroïdes avant de les transmettre au RANSAC circulaire.

Dans `SawadaBSS`, les observations sont renormalisees apres le blanchiment. Ainsi, le clustering EM travaille toujours sur des bins de norme unitaire, que le blanchiment soit active ou non.

3.2 Algorithme de SAWADA

3.2.1 Clustering EM par frequence

Pour chaque frequence f , l'algorithme extrait les observations actives, on utilise le masque donnée par le réseau de neurones ou bien les bins les plus actifs :

$$\tilde{\mathbf{x}}_{f,t}, \quad t \in \mathcal{T}_f.$$

L'objectif est d'ajuster K clusters, ou K est le nombre de sources. Chaque cluster k est represente par trois parametres :

- un centroïde complexe $\mathbf{a}_{f,k}$;
- une variance $\sigma_{f,k}^2$, qui mesure la dispersion autour de la direction ;
- un poids de melange $\alpha_{f,k}$.

L'initialisation est faite par K-means sur les amplitudes des observations, puis les centroïdes sont normalises sur la sphere unite complexe.

3.2.2 Etape E

L'etape E calcule, pour chaque observation, la probabilite posterieure d'appartenir a chaque cluster. La distance directionnelle utilisee est :

$$d_{k,t}^2 = 1 - \left| \mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t} \right|^2.$$

Cette distance est faible lorsque l'observation est proche de la direction du centroïde, independamment d'une phase globale. La probabilite non normalisee associee au cluster k est :

$$q_{k,t} = \alpha_{f,k} \frac{1}{\left(\pi(\sigma_{f,k}^2 + \epsilon) \right)^{M-1}} \exp \left(-\frac{d_{k,t}^2}{\sigma_{f,k}^2 + \epsilon} \right).$$

Les responsabilites EM sont ensuite obtenues par normalisation :

$$\gamma_{k,t} = \frac{q_{k,t}}{\sum_{\ell=1}^K q_{\ell,t} + \epsilon}.$$

3.2.3 Etape M

L'etape M met a jour les parametres des clusters a partir des responsabilites. Les poids de melange sont mis a jour avec un prior de Dirichlet ϕ :

$$\alpha_{f,k} = \frac{\sum_t \gamma_{k,t} + \phi}{N_f + K\phi},$$

ou N_f est le nombre d'observations actives a la frequence f .

Le centroïde est estime comme la direction principale de la matrice de correlation ponderee :

$$\mathbf{R}_{f,k} = \sum_t \gamma_{k,t} \tilde{\mathbf{x}}_{f,t} \tilde{\mathbf{x}}_{f,t}^H.$$

Le nouveau centroïde $\mathbf{a}_{f,k}$ est le vecteur propre principal de $\mathbf{R}_{f,k}$. La variance est ensuite mise a jour comme la dispersion moyenne ponderee des observations autour de cette direction :

$$\sigma_{f,k}^2 = \frac{\sum_t \gamma_{k,t} \left(1 - \left| \mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t} \right|^2 \right)}{(M-1) \sum_t \gamma_{k,t}}.$$

Les demonstrations detaillees de ces trois mises a jour sont donnees en annexe [A](#).

En pratique, ces deux etapes sont alternees un nombre fixe de fois. Dans l'implementation actuelle. Pour 20 itérations, cela fonctionne bien en pratique.

3.2.4 Construction des masques de clusters

Après convergence de l'EM, un masque binaire est construit par décision dure. Pour chaque bin actif, on choisit le cluster avec le plus grand score :

$$\hat{k}(f, t) = \arg \max_k \frac{|\mathbf{a}_{f,k}^H \tilde{\mathbf{x}}_{f,t}|^2}{\sigma_{f,k}^2 + \epsilon}.$$

Le masque du cluster k est alors :

$$M_k(f, t) = \begin{cases} 1 & \text{si } \hat{k}(f, t) = k, \\ 0 & \text{sinon.} \end{cases}$$

A ce stade, les masques sont cohérents localement à une fréquence donnée, mais pas encore globalement entre fréquences. Comme l'EM est lancé indépendamment pour chaque fréquence, le cluster numéroté 0 à une fréquence peut correspondre à une autre source que le cluster numéroté 0 à la fréquence suivante. C'est le problème classique de permutation.

3.3 Assignment des clusters à l'une des sources

3.3.1 Motivation

Pour reconstruire une source, il faut que les masques soient cohérents sur toutes les fréquences. L'implémentation propose deux stratégies d'alignement : une méthode par corrélation d'enveloppes, et une méthode par RANSAC circulaire. La configuration de benchmark utilise l'alignement par RANSAC, car il exploite directement la structure physique des phases relatives.

3.3.2 Alignement par corrélation d'enveloppes

L'assignation par corrélation d'enveloppes consiste à associer, pour chaque fréquence, les clusters locaux aux sources globales déjà suivies aux fréquences précédentes. Pour ce faire, on calcule l'enveloppe $e_k^f(t)$ du cluster k à la fréquence f :

$$e_k^f(t) = \sum_m |X_m(f, t)|^2 M_k(f, t)$$

où $M_k(f, t)$ est le masque binaire du cluster k pour la fréquence f .

On calcule ensuite pour chaque combinaison d'attribution possible

$$\pi \in \mathfrak{S}_K$$

un score de cohérence entre les enveloppes du bin courant et les enveloppes de référence déjà associées aux sources. Si $r_s^{f-1}(t)$ désigne l'enveloppe de référence de la source s construite à partir des fréquences précédentes, le score de la permutation π est :

$$C_f(\pi) = \sum_{s=1}^K \rho \left(e_{\pi(s)}^f(t), r_s^{f-1}(t) \right),$$

ou $\rho(\cdot, \cdot)$ est la corrélation de Pearson :

$$\rho(u, v) = \frac{\sum_t (u(t) - \bar{u})(v(t) - \bar{v})}{\sqrt{\sum_t (u(t) - \bar{u})^2} \sqrt{\sum_t (v(t) - \bar{v})^2 + \epsilon}}.$$

La permutation retenue est celle qui maximise cette corrélation totale :

$$\pi_f^* = \arg \max_{\pi \in \mathfrak{S}_K} C_f(\pi).$$

Les masques de la fréquence f sont ensuite reordonnés selon π_f^* :

$$M_s(f, t) \leftarrow M_{\pi_f^*(s)}(f, t).$$

L'enveloppe de référence est finalement mise à jour de façon progressive. Dans le mode `ema` utilisé par l'implémentation, cette mise à jour prend la forme :

$$r_s^f(t) = (1 - \beta)r_s^{f-1}(t) + \beta e_{\pi_f^*(s)}^f(t),$$

avec $\beta = 0.1$ dans le code. Une fréquence dont l'énergie associée à une source est trop faible ne met pas à jour la référence, afin d'éviter qu'un bin peu informatif dégrade l'alignement des fréquences suivantes.

Cette méthode est simple et ne suppose pas explicitement un modèle de retard. Elle utilise seulement la similarité temporelle des enveloppes : deux clusters appartenant à la même source doivent présenter des activations temporelles corrélées d'une fréquence à l'autre. En revanche, cette méthode ordonne les fréquences car les basses fréquences servent initialement à construire l'enveloppe de référence. Aussi, beaucoup de situation, notamment lors de vocalise simultané, peuvent donner lieu à des erreurs.

3.3.3 RANSAC circulaire

conversion des centroïdes en phase relative

Les centroïdes complexes $\mathbf{a}_{f,k}$ contiennent une phase globale arbitraire. Pour la supprimer, on choisit un microphone de référence, note ici 1, et on calcule :

$$z_{f,k,m}^{\text{rel}} = a_{f,k,m} a_{f,k,1}^*.$$

La phase relative associée est :

$$\theta_{f,k,m} = \arg(z_{f,k,m}^{\text{rel}}).$$

Si le centroïde correspond à une source physique dominée par des retards, alors on attend une relation de la forme :

$$\theta_{f,k,m} \approx b_m - 2\pi f(\tau_m - \tau_1) \pmod{2\pi}.$$

Les phases relatives d'une même source décrivent donc une droite en fréquence, mais observée modulo 2π . Cette propriété est la base du RANSAC circulaire implémenté dans `BSS/CircularRansac`.

Remarque : si l'on a précédemment blanchi les données, il faut penser à faire l'opération inverse sur les centroïdes au risque de faire un ransac sur des données qui ne représentent aucunement des droites

Modèle ajusté par RANSAC circulaire

Le modèle ajusté est une droite circulaire multidimensionnelle :

$$\boldsymbol{\theta}_i = \mathbf{b} + (f_i - f_{\text{ref}})\mathbf{v} \pmod{2\pi}.$$

La distance d'une observation au modèle est calculée après repliement de phase :

$$d_i = \|\text{wrap}(\boldsymbol{\theta}_i - \mathbf{b} - (f_i - f_{\text{ref}})\mathbf{v})\|_2.$$

Concrètement, chaque observation donnée au RANSAC correspond à un centroïde disponible à une fréquence donnée. Elle est décrite par sa fréquence f_i et par son vecteur de phases relatives :

$$\boldsymbol{\theta}_i = [\theta_{i,1} \quad \cdots \quad \theta_{i,M}]^\top.$$

Le RANSAC construit d'abord des hypotheses de trajectoires a partir de petits echantillons d'observations, typiquement deux centroïdes pris a deux frequences distinctes. Pour une paire (i, j) , la pente candidate doit verifier :

$$\theta_j - \theta_i = (f_j - f_i)\mathbf{v} \pmod{2\pi}.$$

Comme les phases sont definies modulo 2π , plusieurs pentes peuvent expliquer la meme paire d'observations :

$$\mathbf{v} = \frac{\theta_j - \theta_i + 2\pi\mathbf{n}}{f_j - f_i}, \quad \mathbf{n} \in \mathbb{Z}^M.$$

L'implementation enumere les hypotheses compatibles avec les bornes physiques sur la pente. Ces bornes proviennent du retard maximal possible entre microphones : comme $v_m = -2\pi\tau_m$, limiter les TDOA revient a limiter les pentes admissibles.

Pour chaque hypothese $(\mathbf{b}, \mathbf{v})$, l'algorithme calcule la distance circulaire de toutes les observations au modele. Une observation est consideree comme un inlier si :

$$d_i < \eta,$$

ou η est le seuil de residu circulaire. Le score utilise est de type MSAC : au lieu de compter seulement les inliers, on somme des residus tronques :

$$S = \sum_i \min(d_i^2, \eta^2).$$

Le meilleur modele est celui qui minimise ce score. Apres selection d'une bonne hypothese, une optimisation locale raffine la pente et l'intercept sur les inliers. Pour une pente fixee, l'intercept optimal est obtenu par moyenne circulaire des phases residuelles :

$$b_m(\mathbf{v}) = \arg \sum_{i \in \mathcal{I}} \exp(j(\theta_{i,m} - (f_i - f_{\text{ref}})v_m)),$$

ou $\mathcal{I}$ designe l'ensemble des inliers.

Comme il y a plusieurs sources, l'extraction est sequentielle. Le RANSAC trouve d'abord la trajectoire la plus coherente, associe les centroïdes compatibles a cette source, puis retire ou marque ces centroïdes avant de chercher la trajectoire suivante. Cette procedure est repetee jusqu'a obtenir K trajectoires, c'est-a-dire une trajectoire de phase par source attendue.

Enfin, tous les centroïdes disponibles sont assignes a la trajectoire la plus proche. Les centroïdes trop eloignes de toutes les trajectoires peuvent etre marques comme non assignes. Les labels obtenus permettent ensuite de fusionner les masques de clusters en masques de sources coherents sur l'ensemble des frequences.

Lien entre pente de phase et TDOA

La pente estimee pour le microphone m a une interpretation directe :

$$v_m = -2\pi(\tau_m - \tau_{\text{ref}}).$$

Le retard relatif au microphone de reference est donc :

$$\tau_m - \tau_{\text{ref}} = -\frac{v_m}{2\pi}.$$

Les TDOA entre paires de microphones sont ensuite calcules par difference :

$$\Delta\tau_{i,j} = \tau_j - \tau_i.$$

En revanche, les tdoas estimé à partir de la pente recupérée dans le RANSAC sont souvent mauvais en comparaison des autres methodes. Cela est donc utile à améliorer la cohérence des mask mais ne sert pas directement au calcul de TDOAS. Il servent principalement à verifier que l'on ne s'est pas totalement trompé.

3.4 Fusion finale des masques

Une fois les centroïdes associés à des sources, les masques de clusters sont fusionnés. Pour une source s , le masque final est :

$$M_s(f, t) = \sum_{k: \text{label}(f, k)=s} M_k(f, t).$$

Dans nos masques, chaque bin actif est associé à un seul cluster. La fusion des clusters assignés à une même source produit donc directement un masque binaire de source. La reconstruction temporelle consiste ensuite à appliquer ce masque à la STFT multicanale originale, puis à revenir dans le domaine temporel par STFT inverse. À noter que le signal temporel reconstruit ne possède pas vraiment une stft similaire à la stft que l'on obtient avec le masque car la stft masqué ne correspond à aucun signal temporel réel. C'est simplement le signal temporel ayant la stft la plus proche de la stft masqué. Ainsi, il n'y a priori aucune raison que les TDOAS calculé soit les bons. On observe dans les faits que cela donne des estimations de TDOAS suffisante.

$$\hat{\mathbf{X}}_s(f, t) = M_s(f, t) \mathbf{X}(f, t),$$

puis à revenir dans le domaine temporel par STFT inverse.

4 Calcul des TDOA à partir des bins isolés

4.1 TDOA sur sources séparées

Une première estimation des TDOA peut être effectuée après reconstruction des sources par istft. Pour chaque source séparée et chaque paire de microphones, le retard est estimé par corrélation temporelle. La convention utilisée est :

$$\Delta\tau_{i,j} = \text{delay}(j) - \text{delay}(i).$$

Cette approche donne une estimation directe sur les signaux temporels reconstruits. Elle dépend cependant de la qualité du masque final : une erreur de séparation ou d'assignation peut détériorer les signaux reconstruits et donc les TDOA calculés par corrélation.

4.2 Beamforming masque

5 Validation sur un dataset synthétique

6 Conclusion

L'algorithme de séparation étudie et exploite la structure physique des signaux multicanaux dans le domaine temps-fréquence. Sous l'hypothèse qu'un bin actif est localement dominé par une source, l'observation multicanale peut être modélisée comme un coefficient complexe multiplié par un vecteur spatial de retards. Cette structure permet de transformer le problème de séparation en un problème de clustering de directions complexes.

Le clustering EM estime, pour chaque fréquence, des centroïdes correspondant aux signatures spatiales locales des sources. Le RANSAC circulaire résout ensuite le problème de permutation entre fréquences en cherchant des trajectoires de phase compatibles avec des retards physiques. Les masques finaux permettent de reconstruire les sources et de calculer des TDOA, soit par corrélation sur les signaux reconstruits, soit à partir des pentes de phase, soit encore en alimentant un beamformer masque.

La validation sur dataset synthétique fournit un cadre reproductible pour mesurer les erreurs de TDOA et inspecter les artefacts internes de l'algorithme. Les prochaines étapes naturelles

consistent a completer les resultats quantitatifs, etudier la sensibilit  aux niveaux de bruit et comparer systematiquement l'apport du masque temps-frequence dans la qualite finale de la separation et des TDOA.

A Demonstrations des mises a jour EM

Dans l'algorithme de Sawada, l'etape M consiste a maximiser l'esperance de la log-vraisemblance complete par rapport aux parametres de chaque source. Pour une frequence donnee, on note $\mathcal{X} = \{\tilde{\mathbf{x}}_t\}_{t=1}^T$ l'ensemble des observations normalisees, avec $\|\tilde{\mathbf{x}}_t\|_2 = 1$. Pour une source i , les parametres sont le centro ide $\mathbf{a}_i$, contraint par $\|\mathbf{a}_i\|_2 = 1$, la variance σ_i^2 et le poids de melange α_i .

La quantite maximisee par l'EM est :

$$Q = \sum_{t=1}^T \sum_{i=1}^K \gamma_{i,t} \left[\ln(\alpha_i) + \ln p(\tilde{\mathbf{x}}_t \mid \mathbf{a}_i, \sigma_i^2) \right].$$

A.1 Mise a jour des poids

Sans regularisation, la mise a jour des poids maximise :

$$\sum_{i=1}^K \sum_{t=1}^T \gamma_{i,t} \ln(\alpha_i) \quad \text{sous la contrainte} \quad \sum_{i=1}^K \alpha_i = 1.$$

En utilisant un multiplicateur de Lagrange λ , on derive :

$$\frac{\partial}{\partial \alpha_i} \left(\sum_{i,t} \gamma_{i,t} \ln(\alpha_i) - \lambda \sum_i \alpha_i \right) = \frac{\sum_t \gamma_{i,t}}{\alpha_i} - \lambda = 0.$$

On obtient donc :

$$\alpha_i = \frac{\sum_t \gamma_{i,t}}{\lambda}.$$

Puisque $\sum_i \alpha_i = 1$, on a :

$$\lambda = \sum_i \sum_t \gamma_{i,t} = T.$$

D'ou :

$$\alpha_i = \frac{\sum_t \gamma_{i,t}}{T}.$$

L'ajout de ϕ dans le code correspond a l'introduction d'un prior de Dirichlet pour regulariser l'estimation. Dans ce cas, la mise a jour devient :

$$\alpha_i = \frac{\sum_t \gamma_{i,t} + \phi}{T + K\phi}.$$

A.2 Mise a jour du centro ide

Le terme de la log-vraisemblance dependant du centro ide $\mathbf{a}_i$ est :

$$Q(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \left(-\frac{\left\| \tilde{\mathbf{x}}_t - \left(\mathbf{a}_i^H \tilde{\mathbf{x}}_t \right) \mathbf{a}_i \right\|_2^2}{\sigma_i^2} \right).$$

Puisque $\|\tilde{\mathbf{x}}_t\|_2 = 1$ et $\|\mathbf{a}_i\|_2 = 1$, la distance a la projection verifie :

$$\left\| \tilde{\mathbf{x}}_t - \left(\mathbf{a}_i^H \tilde{\mathbf{x}}_t \right) \mathbf{a}_i \right\|_2^2 = 1 - \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2.$$

Maximiser $Q(\mathbf{a}_i)$ revient donc a maximiser :

$$\mathcal{J}(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2.$$

Cette quantite peut s'ecrire sous forme quadratique :

$$\mathcal{J}(\mathbf{a}_i) = \sum_{t=1}^T \gamma_{i,t} \mathbf{a}_i^H \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H \mathbf{a}_i = \mathbf{a}_i^H \left(\sum_{t=1}^T \gamma_{i,t} \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H \right) \mathbf{a}_i.$$

En posant :

$$\mathbf{R}_i = \sum_{t=1}^T \gamma_{i,t} \tilde{\mathbf{x}}_t \tilde{\mathbf{x}}_t^H,$$

on cherche :

$$\max_{\mathbf{a}_i} \mathbf{a}_i^H \mathbf{R}_i \mathbf{a}_i \quad \text{sous la contrainte} \quad \mathbf{a}_i^H \mathbf{a}_i = 1.$$

Par la methode des multiplicateurs de Lagrange, on maximise :

$$\mathcal{L} = \mathbf{a}_i^H \mathbf{R}_i \mathbf{a}_i - \lambda \left(\mathbf{a}_i^H \mathbf{a}_i - 1 \right).$$

La condition d'optimalite donne :

$$\mathbf{R}_i \mathbf{a}_i = \lambda \mathbf{a}_i.$$

Le maximum est donc atteint pour le vecteur propre associe a la plus grande valeur propre de $\mathbf{R}_i$. C'est cette operation qui est calculee par la decomposition en valeurs propres dans l'implementation.

A.3 Mise a jour de la variance

La densite de probabilite sur l'hypersphere complexe de dimension M est proportionnelle a :

$$p(\tilde{\mathbf{x}}_t \mid \mathbf{a}_i, \sigma_i^2) = \frac{1}{(\pi \sigma_i^2)^{M-1}} \exp \left(-\frac{1 - \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2}{\sigma_i^2} \right).$$

En posant :

$$d_{i,t}^2 = 1 - \left| \mathbf{a}_i^H \tilde{\mathbf{x}}_t \right|^2,$$

le terme de Q dependant de σ_i^2 s'ecrit :

$$Q(\sigma_i^2) = \sum_{t=1}^T \gamma_{i,t} \left[-(M-1) \ln(\sigma_i^2) - \frac{d_{i,t}^2}{\sigma_i^2} \right].$$

On derive ensuite par rapport a σ_i^2 :

$$\frac{\partial Q}{\partial \sigma_i^2} = -\frac{(M-1) \sum_t \gamma_{i,t}}{\sigma_i^2} + \frac{\sum_t \gamma_{i,t} d_{i,t}^2}{(\sigma_i^2)^2}.$$

En annulant cette derivee, on obtient :

$$(M-1) \sigma_i^2 \sum_t \gamma_{i,t} = \sum_t \gamma_{i,t} d_{i,t}^2.$$

D'ou :

$$\sigma_i^2 = \frac{\sum_t \gamma_{i,t} d_{i,t}^2}{(M-1) \sum_t \gamma_{i,t}}.$$